Analyse des Données

Théorie, méthodes factorielles et applications

ACP · AFC · ACM · Classification · AFD

Master GAMMA · Master Business Analytics

Licence Mathématiques Appliquées (LMAD)

Esprit School of Business

28 avril 2026

Préface

Ce polycopié accompagne le cours d'**Analyse des Données** dispensé aux étudiants de Master GAMMA, Master Business Analytics et Licence Mathématiques Appliquées (LMAD) de l'Esprit School of Business. Il s'inscrit dans la *tradition de l'école française d'analyse des données*, fondée par Jean-Paul Benzécri dans les années 1960 et formalisée par les travaux de Lebart, Morineau, Saporta, Escofier et Pagès.

L'idée directrice du cours est unique :

> *Toute méthode factorielle se ramène à une décomposition en valeurs singulières (SVD) généralisée, dont la lecture géométrique repose sur la notion d'**inertie** et le théorème de **Huygens**.*

Public visé

Ce polycopié s'adresse à des étudiants disposant de connaissances solides en :

— algèbre linéaire (valeurs propres, diagonalisation, formes quadratiques) ;

— statistique descriptive et inférentielle (variance, covariance, tests) ;

— programmation R (manipulation de données, graphiques).

Les étudiants en Mathématiques Appliquées (LMAD) y trouveront les démonstrations détaillées, les étudiants en Business Analytics les interprétations et cas d'usage, et tous bénéficieront du fil conducteur géométrique commun.

Organisation

Le cours suit huit chapitres :

1. Introduction et statistiques descriptives multivariées ;
2. Algèbre linéaire pour l'analyse des données ;
3. Analyse en Composantes Principales (ACP) ;
4. Analyse Factorielle des Correspondances (AFC) ;
5. Analyse des Correspondances Multiples (ACM) ;
6. Classification (CAH, k-means, HCPC) ;
7. Analyse Factorielle Discriminante (AFD) ;
8. Méthodes avancées (MDS, CCA, AFM, PLS, KPCA).

Chaque chapitre contient des définitions, théorèmes (avec démonstrations des plus importants), exemples, code R et exercices.

Travaux pratiques

Quatre TPs en R accompagnent le cours :

— **TP1** — **ACP** : decathlon (FactoMineR) et vins de Bordeaux ;
— **TP2** — **AFC** : CSP × Diplôme et Région × Transport ;
— **TP3** — **ACM** : enquête sur les pratiques numériques ;
— **TP4** — **AFD** : iris et credit scoring.

Tous les jeux de données et leurs scripts de génération sont fournis dans le dépôt GitHub associé.

Esprit School of Business — 28 avril 2026

Table des matières

Préface **ii**

1 Introduction et statistiques descriptives multivariées **1**
1.1 Position de l'analyse des données 1
1.2 Tableau de données 1
1.3 Statistiques descriptives univariées et bivariées 1
1.3.1 Caractéristiques d'une variable quantitative 1
1.3.2 Covariance et corrélation 2
1.3.3 Forme matricielle 2
1.4 Centrage, réduction et tableau standardisé 2
1.5 Distance, métrique et inertie 2
1.6 Théorème de Huygens 3

2 Algèbre linéaire pour l'analyse des données **4**
2.1 Théorème spectral 4
2.2 Quotient de Rayleigh 4
2.3 Décomposition en valeurs singulières (SVD) 5
2.4 Théorème d'Eckart-Young 5
2.5 SVD généralisée et schéma de dualité 5

3 Analyse en Composantes Principales (ACP) **6**
3.1 Formulation et solution 6
3.2 Représentations graphiques et aides à l'interprétation 6
3.3 Choix du nombre d'axes 7
3.4 Code R 7

4 Analyse Factorielle des Correspondances (AFC) **8**
4.1 Cadre et notations 8
4.2 Distance du chi-deux 8
4.3 Décomposition factorielle 8
4.4 Code R 9

5 Analyse des Correspondances Multiples (ACM) **10**
5.1 Tableau disjonctif complet et tableau de Burt 10
5.2 ACM = AFC du TDC 10
5.3 Tableau de Burt et correction de Benzécri 10
5.4 Code R 10

6 Classification **11**
6.1 Critère unificateur 11
6.2 Algorithme k-means 11
6.3 Classification ascendante hiérarchique (CAH) 11

6.4 HCPC : couplage ACP/AFC/ACM + classification 11

7 Analyse Factorielle Discriminante (AFD) 13
7.1 Décomposition de la variance 13
7.2 Critère de Fisher 13
7.3 Cas $K = 2$ groupes 13
7.4 Règle de classement (LDA) 14
7.5 Optimalité bayésienne (cas gaussien) 14
7.6 Code R 14

8 Méthodes avancées 15
8.1 Multidimensional Scaling (MDS) 15
8.2 Analyse canonique des corrélations (CCA) 15
8.3 Analyse Factorielle Multiple (AFM) 15
8.4 Régression PLS 15
8.5 Variantes non linéaires 15
8.6 Conclusion générale 15

Bibliographie 17

Chapitre 1

Introduction et statistiques descriptives multivariées

1.1 Position de l'analyse des données

Définition 1.1 (Analyse des données)**.** L'*analyse des données* (*data analysis*) est l'ensemble des techniques exploratoires *descriptives*, fondées sur la décomposition matricielle et la géométrie des nuages de points, visant à révéler la structure d'un tableau de données $\mathbf{X} \in \mathbb{R}^{n\times p}$ *sans modèle probabiliste*.

L'analyse des données se distingue de la statistique inférentielle (qui postule un modèle probabiliste pour estimer des paramètres et tester des hypothèses) et du *machine learning* supervisé (qui optimise une fonction de prédiction).

Objectifs.

1. **Réduction de dimension** : remplacer p variables corrélées par $q \ll p$ composantes synthétiques.
2. **Visualisation** : projeter les individus et les variables sur des plans interprétables.
3. **Classification** (typologie) : regrouper les individus en classes homogènes.

1.2 Tableau de données

Définition 1.2 (Tableau de données)**.** On note $\mathbf{X} \in \mathbb{R}^{n\times p}$ le tableau où :

— la ligne i représente l'*individu* $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$;

— la colonne j représente la *variable* $\mathbf{x}^j = (x_{1j}, \dots, x_{nj})^\top$.

Selon le type de variables, on choisit la méthode adaptée :

— Quantitatives $\to$ **ACP** (chapitre 3) ;

— Tableau de contingence $\to$ **AFC** (chapitre 4) ;

— Qualitatives nominales $\to$ **ACM** (chapitre 5) ;

— Mixtes $\to$ AFDM, AFM (chapitre 8).

1.3 Statistiques descriptives univariées et bivariées

1.3.1 Caractéristiques d'une variable quantitative

Pour la variable $\mathbf{x}^j$ on définit :

$$\bar{x}^j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \quad s_j^2 = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}^j)^2, \quad s_j = \sqrt{s_j^2}.$$

Remarque 1.3. Nous utilisons la variance *biaisée* (divisée par n) plutôt que la variance corrigée $(n-1)$ car l'analyse géométrique s'appuie sur les moments empiriques sans inférence.

1.3.2 Covariance et corrélation

Définition 1.4 (Covariance et corrélation empiriques)**.**

$$\mathrm{Cov}(\mathbf{x}^j, \mathbf{x}^k) = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}^j)(x_{ik} - \bar{x}^k), \quad \mathrm{Cor}(\mathbf{x}^j, \mathbf{x}^k) = \frac{\mathrm{Cov}(\mathbf{x}^j, \mathbf{x}^k)}{s_j s_k}.$$

Proposition 1.5 (Propriétés de la corrélation)**.** *Pour toutes variables* $\mathbf{x}^j, \mathbf{x}^k$ *:*

1. $\mathrm{Cor}(\mathbf{x}^j, \mathbf{x}^k) \in [-1, 1]$ *(Cauchy-Schwarz) ;*
2. $|\,\mathrm{Cor}\,| = 1 \Leftrightarrow \mathbf{x}^k$ *est fonction affine de* $\mathbf{x}^j$ *;*
3. Cor *est invariante par changement d'unités linéaire ;*
4. $\mathrm{Cor} = 0 \not\Rightarrow$ *indépendance.*

1.3.3 Forme matricielle

On note $\mathbf{X}_c = \mathbf{X} - \mathbb{1}_n \bar{\mathbf{x}}^\top$ le tableau *centré*. La matrice de variance-covariance est

$$\mathbf{V} = \frac{1}{n}\mathbf{X}_c^\top \mathbf{X}_c \ \in \ \mathbb{R}^{p\times p}.$$

La matrice de corrélation est

$$\mathbf{R} = \mathbf{D}_{1/s}\,\mathbf{V}\,\mathbf{D}_{1/s}, \quad \mathbf{D}_{1/s} = \mathrm{diag}(1/s_j).$$

1.4 Centrage, réduction et tableau standardisé

Définition 1.6 (Tableau réduit)**.** Le tableau *centré-réduit* (ou *standardisé*) est

$$\mathbf{Z} = \mathbf{X}_c\,\mathbf{D}_{1/s}, \quad z_{ij} = \frac{x_{ij} - \bar{x}^j}{s_j}.$$

Théorème 1.7 (Effet sur la variance-covariance)**.**

$$\mathbf{V}(\mathbf{X}_c) = \mathbf{V}(\mathbf{X}), \qquad \mathbf{V}(\mathbf{Z}) = \mathbf{R}(\mathbf{X}).$$

Démonstration. Pour $\mathbf{X}_c$, on a $\bar{\mathbf{x}}_c = 0$, donc $\mathbf{V}(\mathbf{X}_c) = \frac{1}{n}\mathbf{X}_c^\top\mathbf{X}_c = \mathbf{V}(\mathbf{X})$. Pour $\mathbf{Z}$, par construction $\mathrm{Var}(z_j) = 1$ et $\mathrm{Cov}(z_j, z_k) = \mathrm{Cor}(x_j, x_k)$, ce qui donne $\mathbf{V}(\mathbf{Z}) = \mathbf{R}(\mathbf{X})$. □

1.5 Distance, métrique et inertie

Définition 1.8 (Métrique)**.** Une *métrique* sur $\mathbb{R}^p$ est une matrice $\mathbf{M}$ symétrique définie positive. La distance associée entre $\mathbf{x}_i$ et $\mathbf{x}_{i'}$ est

$$d^2_{\mathbf{M}}(\mathbf{x}_i, \mathbf{x}_{i'}) = (\mathbf{x}_i - \mathbf{x}_{i'})^\top \mathbf{M}(\mathbf{x}_i - \mathbf{x}_{i'}).$$

Cas particuliers.

— $\mathbf{M} = \mathbf{I}_p$: distance euclidienne classique ;

— $\mathbf{M} = \mathbf{D}_{1/s^2}$: distance euclidienne réduite (ACP normée) ;

— $\mathbf{M} = \mathbf{V}^{-1}$: Mahalanobis (AFD) ;

— $\mathbf{M} = \mathbf{D}_{1/f_{\bullet j}}$: distance du χ^2 (AFC).

Définition 1.9 (Inertie totale d'un nuage)**.** Soit $\mathcal{N} = \{(\mathbf{x}_i, p_i)\}_{i=1}^n$ avec $\sum_i p_i = 1$ et $\mathbf{g} = \sum_i p_i \mathbf{x}_i$ le centre de gravité. L'*inertie totale* de $\mathcal{N}$ par rapport à $\mathbf{g}$ dans la métrique $\mathbf{M}$ est

$$I_{\mathcal{N}} = \sum_{i=1}^{n} p_i \, d^2_{\mathbf{M}}(\mathbf{x}_i, \mathbf{g}).$$

Proposition 1.10 (Inertie et trace)**.** *Avec* $\mathbf{V} = \sum_i p_i (\mathbf{x}_i - \mathbf{g})(\mathbf{x}_i - \mathbf{g})^\top$,

$$I_{\mathcal{N}} = \mathrm{Tr}(\mathbf{VM}).$$

Démonstration. Par cyclicité de la trace, $(\mathbf{x}_i - \mathbf{g})^\top \mathbf{M}(\mathbf{x}_i - \mathbf{g}) = \mathrm{Tr}\big(\mathbf{M}(\mathbf{x}_i - \mathbf{g})(\mathbf{x}_i - \mathbf{g})^\top\big)$. En sommant pondéré sur i, $\sum_i p_i \, \mathrm{Tr}\big(\mathbf{M}(\mathbf{x}_i - \mathbf{g})(\mathbf{x}_i - \mathbf{g})^\top\big) = \mathrm{Tr}(\mathbf{MV}) = \mathrm{Tr}(\mathbf{VM})$. □

1.6 Théorème de Huygens

Théorème 1.11 (Huygens)**.** *Soit* $\mathcal{N}$ *un nuage partitionné en* K *classes* $\mathcal{C}_1, \ldots, \mathcal{C}_K$ *de poids* $P_k = \sum_{i \in \mathcal{C}_k} p_i$ *et de barycentres* $\mathbf{g}_k$*. Alors*

$$\underbrace{\sum_i p_i \, d^2(\mathbf{x}_i, \mathbf{g})}_{I_{tot}} = \underbrace{\sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} p_i \, d^2(\mathbf{x}_i, \mathbf{g}_k)}_{I_{intra}} + \underbrace{\sum_{k=1}^{K} P_k \, d^2(\mathbf{g}_k, \mathbf{g})}_{I_{inter}}.$$

Démonstration. Pour tout $\mathbf{x}_i \in \mathcal{C}_k$, on écrit $\mathbf{x}_i - \mathbf{g} = (\mathbf{x}_i - \mathbf{g}_k) + (\mathbf{g}_k - \mathbf{g})$. Le développement de la norme donne $d^2(\mathbf{x}_i, \mathbf{g}) = d^2(\mathbf{x}_i, \mathbf{g}_k) + d^2(\mathbf{g}_k, \mathbf{g}) + 2\langle \mathbf{x}_i - \mathbf{g}_k, \mathbf{g}_k - \mathbf{g} \rangle_{\mathbf{M}}$. Par définition du barycentre $\mathbf{g}_k$, le double produit s'annule en sommant sur $i \in \mathcal{C}_k$. La pondération sur les classes donne le résultat. □

Ce théorème est fondamental : il fonde le critère du clustering ($\min I_{\text{intra}}$) et de la réduction de dimension ($\max I_{\text{projetée}}$) ainsi que celui de l'AFD ($\max I_{\text{inter}}/I_{\text{intra}}$).

Chapitre 2

Algèbre linéaire pour l'analyse des données

2.1 Théorème spectral

Théorème 2.1 (Théorème spectral)**.** *Soit* $\mathbf{A} \in \mathbb{R}^{p\times p}$ *symétrique réelle. Alors :*

1. *toutes les valeurs propres de* $\mathbf{A}$ *sont réelles ;*
2. *les sous-espaces propres associés à des valeurs propres distinctes sont orthogonaux ;*
3. *il existe une base orthonormée de* $\mathbb{R}^p$ *formée de vecteurs propres de* $\mathbf{A}$*.*

On a la décomposition

$$\mathbf{A} = \mathbf{U}\,\mathbf{\Lambda}\,\mathbf{U}^\top = \sum_{k=1}^{p} \lambda_k\, \mathbf{u}_k \mathbf{u}_k^\top,$$

avec $\mathbf{U}$ *orthogonale et* $\mathbf{\Lambda} = \mathrm{diag}(\lambda_1, \dots, \lambda_p)$*.*

Idée de la démonstration. On procède par récurrence sur p. Pour $p = 1$ trivial. Pour $p \geq 2$, on considère $\mathbf{u}_1$ unitaire maximisant $\mathbf{u}^\top \mathbf{A}\mathbf{u}$: par compacité de la sphère, ce maximum existe et vaut $\lambda_1 = \mathbf{u}_1^\top \mathbf{A}\mathbf{u}_1$. La matrice $\mathbf{A}$ étant symétrique, $\mathbf{u}_1$ est vecteur propre associé. Sur l'orthogonal $\mathbf{u}_1^\perp$ on applique l'hypothèse de récurrence. Les valeurs propres sont réelles car $\mathbf{A}$ est auto-adjointe sur $\mathbb{R}^p$. □

2.2 Quotient de Rayleigh

Définition 2.2 (Quotient de Rayleigh)**.** Pour $\mathbf{A}$ symétrique et $\mathbf{u} \neq 0$:

$$R_{\mathbf{A}}(\mathbf{u}) = \frac{\mathbf{u}^\top \mathbf{A}\mathbf{u}}{\mathbf{u}^\top \mathbf{u}}.$$

Théorème 2.3 (Courant-Fischer-Weyl)**.** *Si* $\lambda_1 \geq \cdots \geq \lambda_p$ *sont les valeurs propres de* $\mathbf{A}$ *symétrique, alors*

$$\lambda_1 = \max_{\mathbf{u}\neq 0} R_{\mathbf{A}}(\mathbf{u}), \quad \lambda_p = \min_{\mathbf{u}\neq 0} R_{\mathbf{A}}(\mathbf{u}), \quad \lambda_k = \max_{\mathbf{u}\perp \mathbf{u}_1,\dots,\mathbf{u}_{k-1}} R_{\mathbf{A}}(\mathbf{u}).$$

Démonstration. On décompose $\mathbf{u} = \sum_j \alpha_j \mathbf{u}_j$ dans la base orthonormée des vecteurs propres. Alors $\mathbf{u}^\top \mathbf{A}\mathbf{u} = \sum_j \lambda_j \alpha_j^2$ et $\mathbf{u}^\top \mathbf{u} = \sum_j \alpha_j^2$. Le quotient s'écrit

$$R_{\mathbf{A}}(\mathbf{u}) = \frac{\sum_j \lambda_j \alpha_j^2}{\sum_j \alpha_j^2} \in [\lambda_p, \lambda_1].$$

Le maximum λ_1 est atteint pour $\mathbf{u} = \mathbf{u}_1$. Pour le k-ième, on impose $\alpha_1 = \cdots = \alpha_{k-1} = 0$ et le maximum vaut λ_k. □

2.3 Décomposition en valeurs singulières (SVD)

Théorème 2.4 (SVD)**.** *Toute matrice* $\mathbf{X} \in \mathbb{R}^{n\times p}$ *admet une décomposition*

$$\mathbf{X} = \mathbf{U}\,\mathbf{\Sigma}\,\mathbf{V}^\top,$$

où $\mathbf{U} \in \mathbb{R}^{n\times n}$ *et* $\mathbf{V} \in \mathbb{R}^{p\times p}$ *sont orthogonales, et* $\mathbf{\Sigma} \in \mathbb{R}^{n\times p}$ *rectangulaire diagonale de coefficients* $\sigma_1 \geq \cdots \geq \sigma_r \geq 0$*,* $r = \mathrm{rang}(\mathbf{X})$*.*

Proposition 2.5 (Lien spectral)**.**

$$\mathbf{X}^\top\mathbf{X} = \mathbf{V}\,(\mathbf{\Sigma}^\top\mathbf{\Sigma})\,\mathbf{V}^\top, \quad \mathbf{X}\mathbf{X}^\top = \mathbf{U}\,(\mathbf{\Sigma}\mathbf{\Sigma}^\top)\,\mathbf{U}^\top.$$

Les valeurs propres communes non nulles sont $\lambda_k = \sigma_k^2$*.*

2.4 Théorème d'Eckart-Young

Théorème 2.6 (Eckart-Young, 1936)**.** *Soit* $\mathbf{X} = \sum_{k=1}^{r} \sigma_k \mathbf{u}_k \mathbf{v}_k^\top$ *la SVD de* $\mathbf{X}$*. Pour tout* $q \leq r$*, la matrice* $\mathbf{X}_q = \sum_{k=1}^{q} \sigma_k \mathbf{u}_k \mathbf{v}_k^\top$ *est l'unique matrice de rang* $\leq q$ *minimisant* $\|\mathbf{X} - \mathbf{Y}\|_F$ *:*

$$\mathbf{X}_q = \operatorname*{arg\,min}_{\mathrm{rang}(\mathbf{Y})\leq q} \|\mathbf{X} - \mathbf{Y}\|_F^2, \quad \|\mathbf{X} - \mathbf{X}_q\|_F^2 = \sum_{k=q+1}^{r} \sigma_k^2.$$

Esquisse. Soit $\mathbf{Y}$ de rang $\leq q$. Pour toute matrice $\mathbf{C}$ de rang q, $\|\mathbf{X} - \mathbf{C}\|_F^2 = \sum_k \sigma_k^2(\mathbf{X} - \mathbf{C})$. La meilleure approximation est obtenue en projetant les composantes singulières dominantes : on garde les q plus grandes σ_k et leurs vecteurs associés. La preuve formelle utilise l'inégalité de Mirsky pour les normes unitairement invariantes. □

Ce théorème fonde toute la réduction de dimension : la *meilleure approximation de rang q* d'un tableau est la projection sur les q premières directions principales.

2.5 SVD généralisée et schéma de dualité

Théorème 2.7 (SVD généralisée)**.** *Soient* $\mathbf{M}$ *une métrique sur* $\mathbb{R}^p$ *et* $\mathbf{D}_p$ *une métrique sur* $\mathbb{R}^n$ *(toutes deux SDP). Alors* $\mathbf{X}$ *admet une décomposition*

$$\mathbf{X} = \mathbf{U}\,\mathbf{\Sigma}\,\mathbf{V}^\top$$

avec $\mathbf{U}^\top\mathbf{D}_p\mathbf{U} = \mathbf{I}$ *et* $\mathbf{V}^\top\mathbf{M}\mathbf{V} = \mathbf{I}$*. Les axes* $\mathbf{v}_k$ *diagonalisent* $\mathbf{X}^\top\mathbf{D}_p\mathbf{X}\mathbf{M}$*.*

Ce cadre unifie l'ACP, l'AFC, l'ACM et l'AFD : chaque méthode correspond à un choix particulier du *triplet* $(\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$.

Chapitre 3

Analyse en Composantes Principales (ACP)

3.1 Formulation et solution

Cadre. $\mathbf{X}_c \in \mathbb{R}^{n\times p}$ centré, métrique $\mathbf{M} = \mathbf{I}_p$ (ACP non normée) ou $\mathbf{M} = \mathbf{D}_{1/s^2}$ (ACP normée), pondération $p_i = 1/n$. On note $\mathbf{V} = \frac{1}{n}\mathbf{X}_c^\top \mathbf{X}_c$.

Théorème 3.1 (Premier axe principal)**.** *Le premier axe principal* $\mathbf{u}_1$ *est la direction unitaire maximisant l'inertie projetée :*

$$\mathbf{u}_1 = \arg\max_{\|\mathbf{u}\|=1} \mathbf{u}^\top \mathbf{V}\mathbf{u}.$$

La solution est le vecteur propre dominant de $\mathbf{V}$ *et le maximum vaut* λ_1*.*

Démonstration. Lagrangien : $\mathcal{L}(\mathbf{u},\mu) = \mathbf{u}^\top\mathbf{V}\mathbf{u} - \mu(\mathbf{u}^\top\mathbf{u} - 1)$. La condition $\nabla_{\mathbf{u}}\mathcal{L} = 2(\mathbf{V}\mathbf{u} - \mu\mathbf{u}) = 0$ donne $\mathbf{V}\mathbf{u} = \mu\mathbf{u}$, et $\mathbf{u}^\top\mathbf{V}\mathbf{u} = \mu$. Le maximum est atteint pour $\mu = \lambda_1$ et $\mathbf{u} = \mathbf{u}_1$ (vecteur propre dominant). □

Définition 3.2 (Composantes principales)**.** Le k-ième axe principal est $\mathbf{u}_k$ vecteur propre de $\mathbf{V}$ associé à λ_k. La k-ième composante principale est $\mathbf{c}_k = \mathbf{X}_c\mathbf{u}_k \in \mathbb{R}^n$.

Proposition 3.3 (Propriétés des composantes)**.**

1. $\bar{c}_k = 0$ *;*
2. $\mathrm{Var}(\mathbf{c}_k) = \lambda_k$ *;*
3. $\mathrm{Cov}(\mathbf{c}_k, \mathbf{c}_l) = 0$ *pour* $k \neq l$ *;*
4. $\sum_k \lambda_k = \mathrm{Tr}(\mathbf{V})$.

Démonstration. (1) Le tableau $\mathbf{X}_c$ est centré donc $\mathbf{X}_c\mathbf{u}_k$ est centré. (2) $\mathrm{Var}(\mathbf{X}_c\mathbf{u}_k) = \mathbf{u}_k^\top\mathbf{V}\mathbf{u}_k = \lambda_k\mathbf{u}_k^\top\mathbf{u}_k = \lambda_k$. (3) $\mathrm{Cov}(\mathbf{X}_c\mathbf{u}_k, \mathbf{X}_c\mathbf{u}_l) = \mathbf{u}_k^\top\mathbf{V}\mathbf{u}_l = \lambda_l\mathbf{u}_k^\top\mathbf{u}_l = 0$ (orthogonalité). (4) $\sum_k \lambda_k = \mathrm{Tr}(\mathbf{\Lambda}) = \mathrm{Tr}(\mathbf{V})$ (par invariance cyclique). □

3.2 Représentations graphiques et aides à l'interprétation

Coordonnées des individus : $F_k(i) = \mathbf{x}_i^\top\mathbf{u}_k$; on les représente sur le plan factoriel (F_1, F_2).

Coordonnées des variables (cercle des corrélations) :

Théorème 3.4. *En ACP normée,* $G_k(\mathbf{x}^j) = \sqrt{\lambda_k}\, u_{kj} = \mathrm{Cor}(\mathbf{x}^j, \mathbf{c}_k)$*, et* $\sum_k G_k(\mathbf{x}^j)^2 \leq 1$.

Définition 3.5 (Aides à l'interprétation)**.** Pour l'individu i sur l'axe k :

$$\cos_k^2(i) = \frac{F_k(i)^2}{\|\mathbf{x}_i - \mathbf{g}\|^2}, \quad \mathrm{ctr}_k(i) = \frac{p_i F_k(i)^2}{\lambda_k}.$$

3.3 Choix du nombre d'axes

Trois critères classiques :

1. **Coude** dans le scree plot λ_k vs k ;
2. **Kaiser** : retenir les $\lambda_k \geq 1$ (ACP normée) ;
3. **KSS** (Karlis-Saporta-Spinaki) : $\lambda_k > 1 + 2\sqrt{(p-1)/(n-1)}$.

3.4 Code R

```r
library(FactoMineR); library(factoextra)
data(decathlon)
res <- PCA(decathlon, scale.unit = TRUE,
           quanti.sup = 11:12, quali.sup = 13, graph = FALSE)
fviz_eig(res, addlabels = TRUE)
fviz_pca_ind(res, col.ind = "cos2", repel = TRUE)
fviz_pca_var(res, col.var = "contrib", repel = TRUE)
```

Exercice 3.1. Démontrer que l'ACP normée est équivalente à une ACP non normée du tableau préalablement standardisé. Conclure que diagonaliser $\mathbf{R}$ revient à diagonaliser $\mathbf{V}(\mathbf{Z})$.

Chapitre 4

Analyse Factorielle des Correspondances (AFC)

4.1 Cadre et notations

Soit $\mathbf{N} = (n_{ij}) \in \mathbb{N}^{I \times J}$ un tableau de contingence. On note $n = \sum_{i,j} n_{ij}$, $f_{ij} = n_{ij}/n$, et les marges $f_{i\bullet}, f_{\bullet j}$.

Définition 4.1 (Profil ligne, profil colonne)**.** $\mathbf{L}_i = (f_{ij}/f_{i\bullet})_j$, $\mathbf{C}_j = (f_{ij}/f_{\bullet j})_i$.

4.2 Distance du chi-deux

Définition 4.2.

$$d^2_{\chi^2}(\mathbf{L}_i, \mathbf{L}_{i'}) = \sum_j \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - \frac{f_{i'j}}{f_{i'\bullet}} \right)^2 .$$

Théorème 4.3 (Inertie totale = Φ^2)**.**

$$I_{tot} = \sum_i f_{i\bullet}\, d^2_{\chi^2}(\mathbf{L}_i, \mathbf{L}_\bullet) = \Phi^2 = \chi^2/n.$$

Démonstration. Le profil moyen ligne est $\mathbf{L}_\bullet = (f_{\bullet j})_j$. On a

$$d^2_{\chi^2}(\mathbf{L}_i, \mathbf{L}_\bullet) = \sum_j \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - f_{\bullet j} \right)^2 = \sum_j \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet}^2 f_{\bullet j}}.$$

En sommant pondéré par $f_{i\bullet}$ et après simplification,

$$I_{\text{tot}} = \sum_{i,j} \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet} f_{\bullet j}} = \frac{1}{n} \sum_{i,j} \frac{(n_{ij} - n f_{i\bullet} f_{\bullet j})^2}{n f_{i\bullet} f_{\bullet j}} = \chi^2/n.$$

□

4.3 Décomposition factorielle

L'AFC se ramène à la SVD du tableau standardisé $s_{ij} = (f_{ij} - f_{i\bullet} f_{\bullet j})/\sqrt{f_{i\bullet} f_{\bullet j}}$.

Théorème 4.4 (Formules de transition)**.**

$$F_k(i) = \frac{1}{\sqrt{\lambda_k}} \sum_j \frac{f_{ij}}{f_{i\bullet}} G_k(j), \quad G_k(j) = \frac{1}{\sqrt{\lambda_k}} \sum_i \frac{f_{ij}}{f_{\bullet j}} F_k(i).$$

Ces formules sont la *lecture barycentrique* du biplot AFC : la position d'une ligne est, à un facteur près, le barycentre des positions des colonnes pondérées par son profil.

4.4 Code R

```r
library(FactoMineR); library(factoextra)
tab <- as.matrix(read.csv("csp_diplome.csv", row.names = 1))
chi <- chisq.test(tab); chi$statistic / sum(tab)   # = Phi^2
res <- CA(tab, graph = FALSE)
fviz_ca_biplot(res, repel = TRUE)
```

Chapitre 5

Analyse des Correspondances Multiples (ACM)

5.1 Tableau disjonctif complet et tableau de Burt

Définition 5.1 (TDC)**.** Soit p variables qualitatives, $K = \sum_j K_j$ modalités. Le tableau disjonctif complet $\mathbf{Z} \in \{0,1\}^{n \times K}$ vérifie $z_{im} = 1$ ssi l'individu i possède la modalité m.

Définition 5.2 (Tableau de Burt)**.** $\mathbf{B} = \mathbf{Z}^\top \mathbf{Z} \in \mathbb{N}^{K \times K}$. Les blocs diagonaux contiennent les effectifs des modalités, les blocs hors-diagonaux les tables de contingence deux à deux.

5.2 ACM = AFC du TDC

Théorème 5.3 (Inertie totale en ACM)**.** $I_{tot} = K/p - 1$.

Démonstration. L'AFC du TDC fait apparaître la marge ligne constante ($z_{i\bullet} = p$) et la marge colonne $z_{\bullet m} = n_m$. En appliquant la formule de l'inertie totale de l'AFC après simplification, on trouve $I_{\text{tot}} = K/p - 1$. □

5.3 Tableau de Burt et correction de Benzécri

Théorème 5.4 (Lien valeurs propres TDC / Burt)**.** *Soient λ_k^Z les valeurs propres de l'AFC du TDC et λ_k^B celles de l'AFC du Burt. Alors $\lambda_k^B = (\lambda_k^Z)^2$.*

Correction de Benzécri. Seuls les axes $\lambda_k > 1/p$ sont significatifs. La part d'inertie corrigée est

$$\tau_k^c = \frac{(\lambda_k - 1/p)^2}{\sum_{l:\lambda_l > 1/p} (\lambda_l - 1/p)^2}.$$

5.4 Code R

```r
library(FactoMineR); library(factoextra)
df <- read.csv("enquete_numerique.csv", stringsAsFactors = TRUE)
res <- MCA(df, quali.sup = 8:9, graph = FALSE)
res$eig
fviz_mca_var(res, repel = TRUE)
```

Chapitre 6

Classification

6.1 Critère unificateur

Une partition $\mathcal{C} = \{\mathcal{C}_1, \ldots, \mathcal{C}_K\}$ minimise I_{intra}, ce qui équivaut à maximiser I_{inter} par le théorème de Huygens.

6.2 Algorithme k-means

Définition 6.1 (Critère k-means)**.** $W(\mathcal{C}) = \sum_k \sum_{i \in \mathcal{C}_k} \|\mathbf{x}_i - \mathbf{g}_k\|^2 = n\, I_{\text{intra}}$.

Théorème 6.2 (Convergence de Lloyd)**.** *La suite $W(\mathcal{C}^{(t)})$ est décroissante et minorée par 0, donc converge en un nombre fini d'itérations vers un minimum local de W.*

Démonstration. À chaque itération : - l'étape d'affectation diminue W (chaque $\mathbf{x}_i$ est affecté au centre le plus proche) ; - l'étape de mise à jour minimise $\sum_{i \in \mathcal{C}_k} \|\mathbf{x}_i - \mathbf{g}\|^2$ en $\mathbf{g} = \mathbf{g}_k$ (centre de gravité). W ne peut prendre qu'un nombre fini de valeurs (il y a K^n partitions), donc la suite stationnaire après un nombre fini d'étapes. □

6.3 Classification ascendante hiérarchique (CAH)

L'algorithme agglomératif fusionne à chaque étape les deux classes les plus proches selon une stratégie de *linkage* δ.

Définition 6.3 (Indice de Ward)**.**

$$\delta_{\text{Ward}}(A, B) = \frac{|A||B|}{|A| + |B|}\, d^2(\mathbf{g}_A, \mathbf{g}_B).$$

Théorème 6.4 (Interprétation comme perte d'inertie)**.** *La fusion de A et B augmente l'inertie intra-classe de $\delta_{Ward}(A, B)$.*

Démonstration. Avant fusion : inertie intra de A et B égale à $\sum_{x \in A} \|x - \mathbf{g}_A\|^2 + \sum_{x \in B} \|x - \mathbf{g}_B\|^2$. Après fusion : inertie intra de $A \cup B$ vaut la somme précédente plus $\frac{|A||B|}{|A|+|B|} d^2(\mathbf{g}_A, \mathbf{g}_B)$, par développement direct (formule de König). D'où le résultat. □

6.4 HCPC : couplage ACP/AFC/ACM + classification

Procédure.

1. Méthode factorielle (ACP, AFC ou ACM) ;
2. Sélection de q axes ;

3. CAH-Ward sur les q premières composantes ;
4. Coupure automatique au plus grand saut ;
5. Consolidation par k-means ;
6. Caractérisation des classes (valeur-test).

Code R.

```
library(FactoMineR); library(factoextra)
data(decathlon)
res.pca <- PCA(decathlon[, 1:10], graph = FALSE)
res.hcpc <- HCPC(res.pca, nb.clust = -1, consol = TRUE, graph = FALSE)
plot(res.hcpc, choice = "tree")
res.hcpc$desc.var
```

Chapitre 7

Analyse Factorielle Discriminante (AFD)

7.1 Décomposition de la variance

Soit $Y \in \{1, \ldots, K\}$ une variable qualitative définissant K groupes $\mathcal{C}_1, \ldots, \mathcal{C}_K$ d'effectifs n_k.

Théorème 7.1 (Décomposition $\mathbf{V} = \mathbf{B} + \mathbf{W}$)**.**

$$\mathbf{B} = \frac{1}{n} \sum_k n_k (\mathbf{g}_k - \mathbf{g})(\mathbf{g}_k - \mathbf{g})^\top, \quad \mathbf{W} = \frac{1}{n} \sum_k \sum_{i \in \mathcal{C}_k} (\mathbf{x}_i - \mathbf{g}_k)(\mathbf{x}_i - \mathbf{g}_k)^\top.$$

On a $\mathbf{V} = \mathbf{B} + \mathbf{W}$.

Démonstration. Pour $\mathbf{x}_i \in \mathcal{C}_k$, $\mathbf{x}_i - \mathbf{g} = (\mathbf{x}_i - \mathbf{g}_k) + (\mathbf{g}_k - \mathbf{g})$. Le produit extérieur $(\mathbf{x}_i - \mathbf{g})(\mathbf{x}_i - \mathbf{g})^\top$ se développe en : $(\mathbf{x}_i - \mathbf{g}_k)(\mathbf{x}_i - \mathbf{g}_k)^\top + (\mathbf{g}_k - \mathbf{g})(\mathbf{g}_k - \mathbf{g})^\top + 2 \cdot$ terme croisé. Le terme croisé s'annule par centrage à $\mathbf{g}_k$ en sommant sur $i \in \mathcal{C}_k$, ce qui donne le résultat. □

7.2 Critère de Fisher

Définition 7.2 (Critère de Fisher)**.**

$$J(\mathbf{u}) = \frac{\mathbf{u}^\top \mathbf{B} \mathbf{u}}{\mathbf{u}^\top \mathbf{W} \mathbf{u}}.$$

Théorème 7.3 (Solution)**.** *Les axes discriminants maximisant J sont les vecteurs propres généralisés $\mathbf{B}\mathbf{u} = \mu \mathbf{W}\mathbf{u}$, soit les vecteurs propres de $\mathbf{W}^{-1}\mathbf{B}$. Le maximum vaut la plus grande valeur propre λ_1.*

Démonstration. On contraint $\mathbf{u}^\top \mathbf{W} \mathbf{u} = 1$ et on maximise $\mathbf{u}^\top \mathbf{B} \mathbf{u}$ par Lagrangien : $\mathcal{L} = \mathbf{u}^\top \mathbf{B} \mathbf{u} - \mu(\mathbf{u}^\top \mathbf{W} \mathbf{u} - 1)$. La condition $\nabla \mathcal{L} = 0$ donne $\mathbf{B}\mathbf{u} = \mu \mathbf{W}\mathbf{u}$. La valeur de J atteinte vaut μ, donc le maximum est λ_1 (plus grande valeur propre de $\mathbf{W}^{-1}\mathbf{B}$). □

7.3 Cas $K = 2$ groupes

Théorème 7.4 (Direction de Fisher pour 2 groupes)**.** *Si $K = 2$, l'unique axe discriminant est, à un scalaire près,*

$$\mathbf{u}^* = \mathbf{W}^{-1}(\mathbf{g}_1 - \mathbf{g}_2).$$

7.4 Règle de classement (LDA)

Définition 7.5 (Règle de Mahalanobis)**.** $\hat{k}(\mathbf{x}^*) = \arg\min_k (\mathbf{x}^* - \mathbf{g}_k)^\top \mathbf{W}^{-1} (\mathbf{x}^* - \mathbf{g}_k)$.

Théorème 7.6 (Forme linéaire)**.** *La frontière entre deux classes k et l est l'hyperplan affine* $\{\mathbf{x} : 2(\mathbf{g}_k - \mathbf{g}_l)^\top \mathbf{W}^{-1}\mathbf{x} = \mathbf{g}_k^\top \mathbf{W}^{-1}\mathbf{g}_k - \mathbf{g}_l^\top \mathbf{W}^{-1}\mathbf{g}_l\}$.

7.5 Optimalité bayésienne (cas gaussien)

Si $(X|Y = k) \sim \mathcal{N}_p(\mu_k, \Sigma)$ avec covariance commune, la règle de Bayes coïncide avec l'AFD à un terme de probabilité a priori près.

Théorème 7.7 (Bayes/Fisher)**.** *Sous gaussianité et homoscédasticité,* $\hat{k}_B(\mathbf{x}) = \arg\min_k (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k) - 2 \ln \pi_k$*, qui se réduit à la règle d'AFD lorsque* $\pi_k = 1/K$.

7.6 Code R

```r
library(MASS); data(iris)
res <- lda(Species ~ ., data = iris)
predict(res)$x      # coordonnees factorielles discriminantes
res.cv <- lda(Species ~ ., data = iris, CV = TRUE)
table(iris$Species, res.cv$class)
```

Chapitre 8

Méthodes avancées

8.1 Multidimensional Scaling (MDS)

Théorème 8.1 (Torgerson)**.** *Étant donnée une matrice de distances* $\mathbf{D} = (d_{ij})$*, soit* $\mathbf{B} = -\frac{1}{2}\mathbf{H}\mathbf{D}^{(2)}\mathbf{H}$ *avec* $\mathbf{H} = \mathbf{I}_n - \frac{1}{n}\mathbb{1}_n\mathbb{1}_n^\top$*. Si* $\mathbf{B}$ *est positive, ses vecteurs propres fournissent des coordonnées* $\mathbf{Y}$ *telles que* $\|\mathbf{y}_i - \mathbf{y}_j\| = d_{ij}$*.*

8.2 Analyse canonique des corrélations (CCA)

Étant donnés deux groupes $\mathbf{X} \in \mathbb{R}^{n\times p}$ et $\mathbf{Y} \in \mathbb{R}^{n\times q}$, la CCA cherche $\mathbf{a}, \mathbf{b}$ maximisant

$$\rho = \mathrm{Cor}(\mathbf{X}\mathbf{a}, \mathbf{Y}\mathbf{b}),$$

solution de $\mathbf{V}_{XX}^{-1}\mathbf{V}_{XY}\mathbf{V}_{YY}^{-1}\mathbf{V}_{YX}\mathbf{a} = \rho^2\mathbf{a}$.

8.3 Analyse Factorielle Multiple (AFM)

L'AFM analyse simultanément J tableaux $\mathbf{X}^{(j)}$ portant sur les mêmes individus, en pondérant chaque bloc par $1/\lambda_1^{(j)}$ pour équilibrer leur influence.

8.4 Régression PLS

Construit des composantes $\mathbf{t}_k = \mathbf{X}\mathbf{w}_k$ maximisant $\mathrm{Cov}(\mathbf{X}\mathbf{w}, \mathbf{Y})$. Très utile lorsque $p \gg n$.

8.5 Variantes non linéaires

- **Kernel PCA** : ACP dans un espace de Hilbert via un noyau ;
- **Isomap** : MDS sur la distance géodésique d'une variété ;
- **LLE** : reconstruction locale par voisinage ;
- **t-SNE, UMAP** : préservation des voisinages probabilistes.

8.6 Conclusion générale

Toutes les méthodes vues s'inscrivent dans le cadre unique de la **SVD généralisée** d'un triplet $(\mathbf{X}, \mathbf{M}, \mathbf{D}_p)$. Le choix de la métrique $\mathbf{M}$ et de la pondération $\mathbf{D}_p$ définit la méthode :

$$\begin{array}{ll} \text{ACP} : (\mathbf{X}_c, \mathbf{I}_p \text{ ou } \mathbf{D}_{1/s^2}, \frac{1}{n}\mathbf{I}_n) & \text{AFC} : (\text{profils}, \mathbf{D}_{1/f_{\bullet j}}, \mathbf{D}_{f_{i\bullet}}) \\ \text{ACM} : (\mathbf{Z}, \frac{n}{p}\mathbf{D}_{1/n_m}, \frac{1}{n}\mathbf{I}_n) & \text{AFD} : (\mathbf{X}_c, \mathbf{W}^{-1}, \frac{1}{n}\mathbf{I}_n) \end{array}$$

Cette unicité algébrique est une force conceptuelle : elle permet de comprendre, critiquer et étendre toute nouvelle méthode factorielle. Le théorème de Huygens fournit l'interprétation géométrique : tout est décomposition d'inertie en parts expliquée et résiduelle.

Bibliographie

Ouvrages fondamentaux (école française)

1. Saporta, G. (2011). *Probabilités, analyse des données et statistique* (3e éd.). Technip.
2. Lebart, L., Morineau, A., & Piron, M. (2006). *Statistique exploratoire multidimensionnelle* (4e éd.). Dunod.
3. Escofier, B., & Pagès, J. (2008). *Analyses factorielles simples et multiples* (4e éd.). Dunod.
4. Husson, F., Lê, S., & Pagès, J. (2017). *Analyse de données avec R* (2e éd.). PUR.
5. Cornillon, P.-A. et al. (2018). *Statistique avec R* (4e éd.). PUR.

Auteurs historiques

6. Benzécri, J.-P. (1973). *L'analyse des données* (2 vol.). Dunod.
7. Cailliez, F., & Pagès, J.-P. (1976). *Introduction à l'analyse des données*. SMASH.
8. Bouroche, J.-M., & Saporta, G. (1980). *L'analyse des données* (*Que sais-je ?*). PUF.

Articles séminaux

9. Pearson, K. (1901). On lines and planes of closest fit. *Phil. Mag.*, 2(11).
10. Hotelling, H. (1933). Analysis of a complex of statistical variables. *J. Educ. Psych.*, 24.
11. Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7.
12. Eckart, C., & Young, G. (1936). The approximation of one matrix by another of lower rank. *Psychometrika*, 1.
13. Hotelling, H. (1936). Relations between two sets of variates. *Biometrika*, 28.
14. Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *JASA*, 58.
15. Torgerson, W. S. (1952). Multidimensional scaling : I. Theory and method. *Psychometrika*, 17.
16. Kruskal, J. B. (1964). Multidimensional scaling. *Psychometrika*, 29.
17. Wold, H. (1975). Soft modelling by latent variables (PLS). *Perspectives in Probability and Statistics*.
18. Schölkopf, B., Smola, A., & Müller, K.-R. (1998). Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5).
19. Tenenbaum, J. B. et al. (2000). A global geometric framework for nonlinear dimensionality reduction. *Science*, 290.
20. Roweis, S. T., & Saul, L. K. (2000). Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290.
21. Candès, E. J. et al. (2011). Robust principal component analysis. *JACM*, 58(3).

Logiciels et packages R

22. Lê, S., Josse, J., & Husson, F. (2008). FactoMineR : An R package for multivariate analysis. *JSS*, 25(1).

23. Kassambara, A., & Mundt, F. (2020). *factoextra*. R package version 1.0.7.
24. Dray, S., & Dufour, A.-B. (2007). The ade4 package. *JSS*, 22(4).
25. Venables, W. N., & Ripley, B. D. (2002). *Modern Applied Statistics with S* (4e éd.). Springer.