Analyse des Données

ACP · AFC · ACM · Classification · AFD

Aymen Ben Brik

Année académique 2025–2026

Esprit School of Business
Master GAMMA · Master BA · Licence LMAD

Plan du cours

1. Introduction et Statistiques Descriptives Multivariées

2. Algèbre Linéaire pour l'Analyse des Données

3. Analyse en Composantes Principales (ACP)

4. Analyse Factorielle des Correspondances (AFC)

5. Analyse des Correspondances Multiples (ACM)

6. Classification

7. Analyse Factorielle Discriminante (AFD)

Introduction et Statistiques Descriptives Multivariées

1.1 — Qu'est-ce que l'analyse des données ?

Definition

L'**analyse des données** (*data analysis*) est l'ensemble des techniques exploratoires descriptives, fondées sur la **décomposition matricielle** et la **géométrie des nuages de points**, visant à révéler la structure d'un tableau de données $X \in \mathbb{R}^{n \times p}$ *sans modèle probabiliste*.

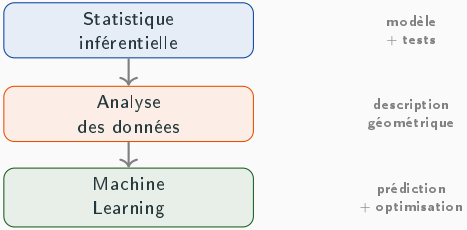

Tradition française (Benzécri, années 1960) :

- Géométrique (inertie, projections orthogonales)
- Descriptive (pas d'hypothèses inférentielles)
- Visuelle (cartes factorielles)

1.1 — Objectifs de l'analyse des données

Trois grands objectifs

1. **Réduire la dimension** : remplacer p variables corrélées par $q \ll p$ *composantes synthétiques*.
2. **Représenter graphiquement** les individus et les variables sur des plans factoriels.
3. **Classifier** (typer) les individus en groupes homogènes.

Méthodes selon le type de données

- Quantitatives $\rightarrow$ ACP
- Tableau de contingence $\rightarrow$ AFC
- Qualitatives $\rightarrow$ ACM
- Mixtes $\rightarrow$ AFDM, AFM

Place de ce cours

Articulation entre :

- **algèbre linéaire** (LMAD, théorèmes)
- **statistique multivariée** (GAMMA)
- **interprétation métier** (BA)

Différence avec le ML supervisé

Pas de variable cible y : on cherche à décrire et comprendre la structure, pas à prédire.

1.2 — Le tableau de données

Definition (Tableau de données)

On note $\mathrm{X} \in \mathbb{R}^{n \times p}$ le tableau dont la ligne i (individu) est $\mathrm{x}_i = (x_{i1}, \ldots, x_{ip})^\top \in \mathbb{R}^p$, et la colonne j (variable) est $\mathrm{x}^j = (x_{1j}, \ldots, x_{nj})^\top \in \mathbb{R}^n$.

Deux lectures

- **Ligne** : nuage des n individus dans $\mathbb{R}^p$
- **Colonne** : nuage des p variables dans $\mathbb{R}^n$

Types de variables

- *Quantitatives* (continues, discrètes) : ACP
- *Qualitatives nominales* : ACM
- *Qualitatives ordinales* : recodage prudent
- *Effectifs / contingence* : AFC

	V_1	V_2	$\cdots$	V_p
i_1	x_{11}	x_{12}	$\cdots$	x_{1p}
i_2	x_{21}	x_{22}	$\cdots$	x_{2p}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
i_n	x_{n1}	x_{n2}	$\cdots$	x_{np}

Exemple

Tableau `decathlon` : $n = 41$ athlètes, $p = 10$ disciplines + classement.

1.3 — Caractéristiques d'une variable

Tendance centrale

$$\bar{x}^j = \frac{1}{n}\sum_{i=1}^{n} x_{ij} \quad \text{(moyenne arithmétique)}$$

$$\tilde{x}^j = \text{médiane}(\mathrm{x}^j)$$

Dispersion

$$s_j^2 = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}^j)^2 \quad \text{(variance empirique)}$$

$$s_j = \sqrt{s_j^2} \quad \text{(écart-type)}$$

Remarque

On utilise ici la variance biaisée (divisée par n), adaptée à l'analyse géométrique.

Quantiles et étendue

- $Q_1, Q_2 = \tilde{x}, Q_3$: quartiles
- $IQR = Q_3 - Q_1$: écart interquartile
- Étendue : $\max - \min$

Forme

- Asymétrie (skewness) : $\gamma_1 = \mathbb{E}[(X-\mu)^3]/\sigma^3$
- Aplatissement (kurtosis) : $\gamma_2 = \mathbb{E}[(X-\mu)^4]/\sigma^4 - 3$

Présence d'outliers

Préférer $\tilde{x}$ et IQR à $\bar{x}$ et s pour résumer une variable contaminée.

1.4 — Liaison entre deux variables

Definition (Covariance et corrélation empiriques)

Pour deux variables $\mathrm{x}^j, \mathrm{x}^k \in \mathbb{R}^n$:

$$\mathrm{Cov}(\mathrm{x}^j, \mathrm{x}^k) = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}^j)(x_{ik} - \bar{x}^k), \qquad \mathrm{Cor}(\mathrm{x}^j, \mathrm{x}^k) = \frac{\mathrm{Cov}(\mathrm{x}^j, \mathrm{x}^k)}{s_j\, s_k}.$$

Proposition (Propriétés de la corrélation)

1. $\mathrm{Cor}(\mathrm{x}^j, \mathrm{x}^k) \in [-1, 1]$ *(Cauchy-Schwarz)*
2. $|\,\mathrm{Cor}\,| = 1 \iff \mathrm{x}^k$ *est fonction affine de* x^j
3. Cor *est invariante par changement d'unités linéaire (échelle, origine)*
4. $\mathrm{Cor} = 0 \not\Rightarrow$ *indépendance (mesure uniquement la liaison linéaire)*

Forme matricielle

$\mathrm{V} = \frac{1}{n}\mathrm{X}_c^\top \mathrm{X}_c$: matrice de variance-covariance $(p \times p)$.
$\mathrm{R} = \mathrm{D}_{1/s}\,\mathrm{V}\,\mathrm{D}_{1/s}$: matrice de corrélation, où $\mathrm{D}_{1/s} = \mathrm{diag}(1/s_i)$.

1.5 — Centrage et réduction

Centrage

$$X_c = X - \mathbb{1}_n \bar{x}^\top, \quad \bar{x} = \frac{1}{n} X^\top \mathbb{1}_n$$

$\Leftrightarrow$ déplacer l'origine au centre de gravité g.

Réduction (standardisation)

$$Z = X_c \, D_{1/s}, \quad z_{ij} = \frac{x_{ij} - \bar{x}^j}{s_j}$$

$\Leftrightarrow$ rendre les variables adimensionnelles.

Theorem (Effet sur la variance-covariance)

$$V(X_c) = V(X), \qquad V(Z) = R(X).$$

Pourquoi réduire ?

- Variables d'unités différentes (kg, EUR, années)
- Variances très différentes
- Sans réduction, l'ACP est dominée par la variable de plus grande variance

Quand ne pas réduire ?

Lorsque les variables sont **de même nature** et de variances comparables (ex : températures aux mois de l'année).

1.6 — Distance entre individus

Definition (Métrique)

Une **métrique** sur $\mathbb{R}^p$ est une matrice M symétrique définie positive. La distance associée entre x_i et $x_{i'}$ est :

$$d^2_{\mathrm{M}}(x_i, x_{i'}) = (x_i - x_{i'})^\top \mathrm{M}(x_i - x_{i'}).$$

Cas particuliers

- $\mathrm{M} = \mathrm{I}_p$: distance euclidienne classique
  $d^2 = \sum_j (x_{ij} - x_{i'j})^2$
- $\mathrm{M} = \mathrm{D}_{1/s^2}$: distance euclidienne réduite
  $d^2 = \sum_j \frac{(x_{ij} - x_{i'j})^2}{s_j^2}$
- $\mathrm{M} = \mathrm{V}^{-1}$: Mahalanobis
- $\mathrm{M} = \mathrm{D}_{1/x_{\bullet j}}$: χ^2 (AFC)

Proposition (Choix de la métrique)

Le choix de M *définit l'analyse :*

- *ACP normée* $\equiv$ *ACP centrée avec* $\mathrm{M} = \mathrm{D}_{1/s^2}$
- *AFC : tableau de profils,* M_{χ^2}
- *AFD :* $\mathrm{M} = \mathrm{V}_{intra}^{-1}$

Pondération des individus

Chaque individu a un poids $p_i \geq 0$ tel que $\sum_i p_i = 1$. Cas usuel : $p_i = 1/n$.

1.7 — Inertie : la mesure de l'analyse des données

Definition (Inertie totale d'un nuage)

Soit $\mathcal{N} = \{(\mathrm{x}_i, p_i)\}_{i=1}^n$ un nuage pondéré de centre de gravité $\mathrm{g} = \sum_i p_i \mathrm{x}_i$. L'**inertie totale** de $\mathcal{N}$ par rapport à g, dans la métrique M, est :

$$I_{\mathcal{N}} = \sum_{i=1}^n p_i \, d_{\mathrm{M}}^2(\mathrm{x}_i, \mathrm{g}) = \sum_{i=1}^n p_i \, (\mathrm{x}_i - \mathrm{g})^\top \mathrm{M} (\mathrm{x}_i - \mathrm{g}).$$

Proposition (Lien avec la trace)

Soit $\mathrm{V} = \sum_i p_i (\mathrm{x}_i - \mathrm{g})(\mathrm{x}_i - \mathrm{g})^\top$ *la matrice de variance-covariance pondérée. Alors :*

$$\boxed{I_{\mathcal{N}} = \mathrm{Tr}(\mathrm{VM}).}$$

Remarque

Pour $\mathrm{M} = \mathrm{I}_p$ et $p_i = 1/n$: $I_{\mathcal{N}} = \mathrm{Tr}(\mathrm{V}) = \sum_j s_j^2$, soit la **somme des variances** des variables.
En ACP normée : $I_{\mathcal{N}} = \mathrm{Tr}(\mathrm{R}) = p$.

1.8 — Théorème de Huygens (décomposition de l'inertie)

Theorem (Huygens)

Soit $\mathcal{N}$ un nuage partitionné en K classes $\mathcal{C}_1, \ldots, \mathcal{C}_K$ de poids respectifs $P_k = \sum_{i \in \mathcal{C}_k} p_i$ et de barycentres $\mathrm{g}_k = \frac{1}{P_k} \sum_{i \in \mathcal{C}_k} p_i \mathrm{x}_i$. Alors :

$$\boxed{\underbrace{\sum_i p_i \, d^2(\mathrm{x}_i, \mathrm{g})}_{I_{totale}} = \underbrace{\sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} p_i \, d^2(\mathrm{x}_i, \mathrm{g}_k)}_{I_{intra}} + \underbrace{\sum_{k=1}^{K} P_k \, d^2(\mathrm{g}_k, \mathrm{g})}_{I_{inter}}.}$$

Conséquences fondamentales

- Clustering : minimiser $I_{\text{intra}} \Leftrightarrow$ maximiser I_{inter} (k-means)
- Réduction de dimension : maximiser l'inertie projetée $\Leftrightarrow$ minimiser l'inertie résiduelle (ACP)
- AFD : critère de Fisher max $I_{\text{inter}}/I_{\text{intra}}$

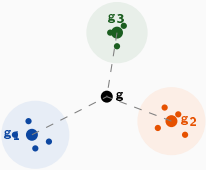

1.9 — Dualité individus / variables

Nuage des individus $\mathcal{N}_I$ dans $\mathbb{R}^p$

- n points x_i
- Métrique M sur $\mathbb{R}^p$
- Pondération $D_p = \text{diag}(p_i)$
- Centre g, inertie Tr(VM)

Nuage des variables $\mathcal{N}_V$ dans $\mathbb{R}^n$

- p points x^j
- Métrique D_p sur $\mathbb{R}^n$
- Pondération M sur les variables
- Produit scalaire $\langle x^j, x^k \rangle = \text{Cov}(x^j, x^k)$

Theorem (Dualité)

Les deux nuages $\mathcal{N}_I$ et $\mathcal{N}_V$ partagent les mêmes valeurs propres non nulles. La même décomposition matricielle (SVD de X) fournit simultanément :

- *les axes principaux de $\mathcal{N}_I$*
- *les axes principaux de $\mathcal{N}_V$*

Conséquence pratique

Les **individus** et les **variables** se représentent sur les *mêmes* plans factoriels (biplot) — l'ACP est auto-duale.

1.10 — Aperçu : statistiques descriptives en R

```r
library(FactoMineR)     # methodes factorielles
library(factoextra)     # visualisation
library(corrplot)       # matrice de correlations

data(decathlon)         # 41 athletes x 13 variables
X <- decathlon[, 1:10]  # variables actives quantitatives

# Statistiques univariees
summary(X)
sapply(X, sd)

# Centrage / reduction
Z <- scale(X)           # par defaut center=TRUE, scale=TRUE
colMeans(Z); apply(Z, 2, sd)

# Matrice de variance-covariance et de correlation
V <- cov(X)             # divise par n-1 (correction de Bessel)
R <- cor(X)
corrplot(R, method = "color", type = "upper", tl.cex = 0.7)

# Inertie totale (ACP normee)
sum(diag(R))            # = nombre de variables = 10
```

1.11 — Récapitulatif du chapitre

Concepts à retenir

- Tableau $X \in \mathbb{R}^{n \times p}$, deux lectures (individus / variables)
- Matrice de variance-covariance $V = \frac{1}{n} X_c^\top X_c$
- Matrice de corrélation R
- Centrage (décalage), réduction (échelle)
- Métrique M symétrique définie positive
- Inertie $I = \mathrm{Tr}(VM)$
- Théorème de Huygens : $I = I_{\text{intra}} + I_{\text{inter}}$

À venir

Chapitre 2 : algèbre linéaire pour l'analyse des données

- Théorème spectral
- Décomposition en valeurs singulières (SVD)
- Théorème d'Eckart-Young
- Projections orthogonales

Idée directrice

Toute l'analyse des données est une **décomposition d'inertie** via la diagonalisation d'une matrice symétrique.

Algèbre Linéaire pour l'Analyse des Données

2.1 — Rappels d'algèbre linéaire

Definition (Valeur propre, vecteur propre)

Soit $A \in \mathbb{R}^{p \times p}$. Un scalaire $\lambda \in \mathbb{R}$ est dit **valeur propre** de A s'il existe $u \in \mathbb{R}^p \setminus \{0\}$ tel que $Au = \lambda u$. Le vecteur u est le **vecteur propre** associé.

Polynôme caractéristique

$$P_A(\lambda) = \det(A - \lambda I_p)$$

Les valeurs propres sont les racines de P_A dans $\mathbb{C}$.

Spectre : $\sigma(A) = \{\lambda_1, \ldots, \lambda_p\}$ (comptées avec multiplicité).

Sous-espace propre

$$E_\lambda = \ker(A - \lambda I_p)$$

Proposition (Trace et déterminant)

$$\mathrm{Tr}(A) = \sum_{i=1}^{p} \lambda_i, \qquad \det(A) = \prod_{i=1}^{p} \lambda_i.$$

Proposition (Diagonalisation)

A est diagonalisable si et seulement si la somme des dimensions des sous-espaces propres vaut p :

$$\sum \dim(E_\lambda) = p.$$

2.2 — Théorème spectral pour matrices symétriques

Theorem (Théorème spectral)

Soit $A \in \mathbb{R}^{p \times p}$ *une matrice symétrique réelle* ($A^\top = A$). *Alors :*

1. *Toutes les valeurs propres de* A *sont* ***réelles***.
2. *Les sous-espaces propres associés à des valeurs propres distinctes sont* ***orthogonaux***.
3. *Il existe une* ***base orthonormée*** $\{u_1, \ldots, u_p\}$ *de* $\mathbb{R}^p$ *formée de vecteurs propres de* A.

On a la décomposition :

$$\boxed{A = U \tilde{} U^\top = \sum_{k=1}^{p} \lambda_k u_k u_k^\top}$$

avec U *orthogonale* ($U^\top U = I_p$) *et* $\tilde{} = diag(\lambda_1, \ldots, \lambda_p)$.

Remarque (Conséquence majeure)

La matrice de variance-covariance V et la matrice de corrélation R sont symétriques réelles : elles admettent toujours une base orthonormée de vecteurs propres. C'est le **cœur** de l'ACP.

2.3 — Formes quadratiques et matrices SDP

Definition (Forme quadratique)

À toute matrice symétrique $A \in \mathbb{R}^{p \times p}$ on associe la **forme quadratique**

$$q_A : \mathbb{R}^p \to \mathbb{R}, \quad q_A(x) = x^\top A\, x.$$

Definition (Matrice positive / définie positive)

- A est **positive** ($A \succeq 0$) si $q_A(x) \geq 0$ pour tout x.
- A est **définie positive** ($A \succ 0$) si $q_A(x) > 0$ pour tout $x \neq 0$.

Theorem (Caractérisation par les valeurs propres)

Soit A symétrique réelle. Alors :

$$A \succeq 0 \iff \forall k,\ \lambda_k \geq 0, \qquad A \succ 0 \iff \forall k,\ \lambda_k > 0.$$

Remarque

V et R sont toujours positives car $V = \frac{1}{n} X^\top X$; pour tout u, $u^\top V u = \frac{1}{n} \|X\, u\|^2 \geq 0$

2.4 — Quotient de Rayleigh

Definition (Quotient de Rayleigh)

Soit A symétrique réelle et $\mathrm{u} \in \mathbb{R}^p \setminus \{0\}$. Le **quotient de Rayleigh** est :

$$R_{\mathrm{A}}(\mathrm{u}) = \frac{\mathrm{u}^\top \mathrm{A}\,\mathrm{u}}{\mathrm{u}^\top \mathrm{u}}.$$

Theorem (Courant-Fischer-Weyl)

Soient $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$ les valeurs propres de A (symétrique). Alors :

$$\boxed{\lambda_1 = \max_{\mathrm{u}\neq 0} R_{\mathrm{A}}(\mathrm{u}), \qquad \lambda_p = \min_{\mathrm{u}\neq 0} R_{\mathrm{A}}(\mathrm{u}).}$$

Plus généralement, pour le k-ième axe :

$$\lambda_k = \max_{\substack{\mathrm{u}\perp \mathrm{u}_1,\ldots,\mathrm{u}_{k-1} \\ \mathrm{u}\neq 0}} R_{\mathrm{A}}(\mathrm{u}).$$

Remarque (Importance pour l'ACP)

2.5 — Décomposition en valeurs singulières (SVD)

Theorem (SVD)

Toute matrice $X \in \mathbb{R}^{n \times p}$ *admet une décomposition*

$$\boxed{X = U \circ V^\top}$$

où :

- $U \in \mathbb{R}^{n \times n}$ *orthogonale* ($U^\top U = I_n$)
- $V \in \mathbb{R}^{p \times p}$ *orthogonale* ($V^\top V = I_p$)
- $\circ \in \mathbb{R}^{n \times p}$ *rectangulaire diagonale, de coefficients diagonaux* $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0$, *où* $r = \mathrm{rang}(X)$.

Les σ_k *sont les* ***valeurs singulières****, les colonnes de* U *et* V *sont les* ***vecteurs singuliers à gauche*** *et* ***à droite****.*

Proposition (Forme dyadique / SVD réduite)

$$X = \sum^{r} \sigma_k u_k v_k^\top.$$

2.6 — Lien entre SVD et décomposition spectrale

Theorem (Spectres de $X^\top X$ et $XX^\top$)

Soit $X = U \circ V^\top$ la SVD de X. Alors :

$$X^\top X = V \circ^\top \circ V^\top, \qquad XX^\top = U \circ \circ^\top U^\top.$$

Les valeurs propres communes (non nulles) sont $\lambda_k = \sigma_k^2$.

Démonstration (idée).

$$X^\top X = (U \circ V^\top)^\top (U \circ V^\top) = V \circ^\top U^\top U \circ V^\top$$

$= V(\circ^\top \circ)V^\top$ car $U^\top U = I_n$. La matrice $\circ^\top \circ$ est diagonale de coefficients σ_k^2.

Conséquence pour l'ACP

La SVD de X_c donne directement :

- Les axes principaux : colonnes de V
- Les composantes principales : $C = X_c V$
- Les inerties expliquées : $\lambda_k = \sigma_k^2$

En pratique

On utilise la **SVD numérique** pour calculer

2.7 — Théorème d'Eckart-Young-Mirsky

Theorem (Eckart-Young, 1936)

Soit $X = \sum_{k=1}^{r} \sigma_k u_k v_k^\top$ *la SVD de* X. *Pour tout entier* $q \leq r$, *la matrice*

$$X_q = \sum_{k=1}^{q} \sigma_k \, u_k v_k^\top$$

est l'unique matrice de rang $\leq q$ *minimisant l'erreur de Frobenius :*

$$X_q = \underset{\text{rang}(Y) \leq q}{\arg\min} \, \|X - Y\|_F^2, \quad \textit{avec} \quad \|X - X_q\|_F^2 = \sum_{k=q+1}^{r} \sigma_k^2.$$

Norme de Frobenius

$$\|A\|_F^2 = \sum_{i,j} a_{ij}^2 = \text{Tr}(A^\top A) = \sum_k \sigma_k^2.$$

Remarque (Interprétation pour l'analyse des données)

Eckart-Young fonde toute la réduction de dimension : la **meilleure approximation de rang** q d'un

2.8 — Projections orthogonales

Definition (Projecteur orthogonal)

Soit F un sous-espace vectoriel de $\mathbb{R}^p$. Le **projecteur orthogonal** sur F est l'unique application linéaire $\mathrm{P}_F : \mathbb{R}^p \to F$ telle que $\mathrm{x} - \mathrm{P}_F(\mathrm{x}) \perp F$ pour tout x. Il vérifie : $\mathrm{P}_F^2 = \mathrm{P}_F$ et $\mathrm{P}_F^\top = \mathrm{P}_F$.

Proposition (Forme matricielle)

Si $\{\mathrm{u}_1, \ldots, \mathrm{u}_q\}$ *est une base orthonormée de* F *et* $\mathrm{U} = [\mathrm{u}_1 \mid \cdots \mid \mathrm{u}_q]$, *alors :*

$$\mathrm{P}_F = \mathrm{U}\mathrm{U}^\top.$$

La projection de x *est* $\mathrm{P}_F(\mathrm{x}) = \mathrm{U}(\mathrm{U}^\top \mathrm{x}) = \sum_{k=1}^q \langle \mathrm{x}, \mathrm{u}_k \rangle \mathrm{u}_k$.

Theorem (Théorème de Pythagore)

Pour tout $\mathrm{x} \in \mathbb{R}^p$ *:*

$$\|\mathrm{x}\|^2 = \|\mathrm{P}_F(\mathrm{x})\|^2 + \|\mathrm{x} - \mathrm{P}_F(\mathrm{x})\|^2.$$

Remarque

2.9 — Inertie projetée et meilleur sous-espace

Theorem (Décomposition de l'inertie)

Soit $\mathcal{N}$ un nuage centré de matrice de variance-covariance V, et F_q le sous-espace engendré par les q premiers vecteurs propres de V. Alors l'inertie totale se décompose comme :

$$\boxed{I_{totale} = \underbrace{\sum_{k=1}^{q} \lambda_k}_{\text{inertie projetée sur } F_q} + \underbrace{\sum_{k=q+1}^{p} \lambda_k}_{\text{inertie résiduelle}} .}$$

F_q est le sous-espace de dimension q maximisant l'inertie projetée.

Proposition (Pourcentage d'inertie expliquée)

La part d'inertie expliquée par les q premiers axes est :

$$\tau_q = \frac{\lambda_1 + \cdots + \lambda_q}{\lambda_1 + \cdots + \lambda_p} \in [0, 1].$$

On choisit q pour que τ_q atteigne un seuil (ex : 80%).

2.10 — Décomposition généralisée (avec métrique M)

Theorem (SVD généralisée)

Soient M *une métrique sur* $\mathbb{R}^p$ *et* D_p *une métrique sur* $\mathbb{R}^n$ *(symétriques définies positives). Il existe une décomposition de* X

$$X = U \circ V^\top$$

avec $U^\top D_p U = I$ *et* $V^\top M V = I$. *Les vecteurs propres* v_k *diagonalisent* $X^\top D_p X M$.

Cadre unificateur

Toutes les méthodes factorielles s'écrivent comme une SVD généralisée d'un triplet (X, M, D_p) :

- ACP : $M = I_p$ ou D_{1/s^2}, $D_p = \frac{1}{n} I_n$
- AFC : $M = D_{1/x_{\bullet j}}$, D_p liée aux profils
- ACM : AFC du tableau disjonctif
- AFD : $M = V_{\text{intra}}^{-1}$

Vue duale

Le **schéma de dualité** (Cailliez-Pagès) :

$$X^\top D_p X M \overset{\text{spectres}}{\equiv} X M X^\top D_p$$

Mêmes valeurs propres non nulles : c'est la dualité individus/variables.

Conséquence

Une seule machine algébrique — la SVD généralisée — couvre l'*ensemble* des méthodes

2.11 — Algèbre linéaire en R

```r
# Matrice symetrique definie positive
set.seed(42)
A <- matrix(rnorm(16), 4, 4); A <- t(A) %*% A   # symetrique, SDP

# Decomposition spectrale
res <- eigen(A)
res$values     # valeurs propres (decroissantes)
res$vectors    # vecteurs propres en colonnes (orthonormes)

# Verification : A = U D U^T
U <- res$vectors; D <- diag(res$values)
all.equal(A, U %*% D %*% t(U))   # TRUE

# SVD d'une matrice generale
X <- matrix(rnorm(20), 5, 4)
svd_res <- svd(X)
svd_res$d      # valeurs singulieres
svd_res$u; svd_res$v

# Verification : X = U Sigma V^T
all.equal(X, svd_res$u %*% diag(svd_res$d) %*% t(svd_res$v))  # TRUE

# Approximation de rang 2 (Eckart-Young)
X2 <- svd_res$u[, 1:2] %*% diag(svd_res$d[1:2]) %*% t(svd_res$v[, 1:2])
```

2.12 — Récapitulatif du chapitre

Théorèmes à retenir

- **Spectral** : A symétrique réelle $\Rightarrow$ base orthonormée de vecteurs propres $A = U \tilde{} U^\top$
- **Courant-Fischer-Weyl** : $\lambda_1 = \max R_A(u)$
- **SVD** : $X = U \circ V^\top$ pour toute matrice
- **Eckart-Young** : meilleure approximation de rang q
- **Pythagore** : $\|x\|^2 = \|P_F x\|^2 + \|x - P_F x\|^2$

Pont vers l'ACP

Toutes les briques sont en place :

1. Variance-covariance V symétrique SDP
2. Théorème spectral $\Rightarrow$ axes propres orthogonaux
3. Quotient de Rayleigh $\Rightarrow$ inertie projetée maximale
4. Eckart-Young $\Rightarrow$ ACP est optimale

Idée maîtresse

L'ACP, l'AFC, l'ACM, l'AFD sont une seule et même opération : diagonaliser une matrice symétrique pour décomposer une inertie.

Analyse en Composantes Principales (ACP)

3.1 — Pourquoi l'ACP ?

Données : tableau $X \in \mathbb{R}^{n \times p}$ de p variables quantitatives (souvent corrélées).

Trois objectifs

1. Construire $q \ll p$ nouvelles variables non corrélées résumant l'information.
2. Visualiser le nuage des individus en 2D / 3D.
3. Étudier la structure des corrélations entre variables.

Origine historique

- Pearson (1901) : meilleur ajustement d'un sous-espace
- Hotelling (1933) : composantes principales
- École française (Cazes, Saporta) : formalisation géométrique

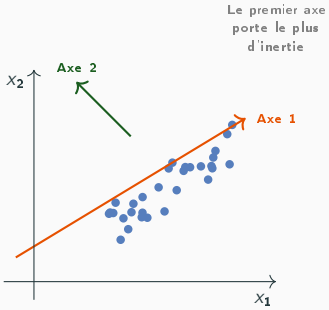

3.2 — Formulation : axe d'inertie maximale

Cadre

X_c centré, métrique M sur $\mathbb{R}^p$, pondération $p_i = 1/n$. $V = \frac{1}{n} X_c^\top X_c$: matrice de variance-covariance.

Premier axe principal u_1

On cherche $u_1 \in \mathbb{R}^p$ unitaire ($u_1^\top M u_1 = 1$) maximisant l'inertie projetée :

$$u_1 = \underset{u^\top M u = 1}{\arg\max} \sum_{i=1}^{n} p_i \left(u^\top M x_i\right)^2 = \underset{u^\top M u = 1}{\arg\max}\, u^\top M V M u.$$

Theorem (Solution)

Le premier axe principal u_1 *est le vecteur propre de* VM *associé à la plus grande valeur propre* λ_1. *La maximum atteint vaut* λ_1 *: c'est la plus grande variance portée par un axe.*

Cas euclidien classique ($M = I_p$) : $V u_1 = \lambda_1 u_1$, donc u_1 est le vecteur propre dominant de V.

3.3 — Démonstration (cas $M = I_p$)

Problème : $\max_{u} \; u^\top V u \quad \text{sous} \quad u^\top u = 1.$

Lagrangien

$$\mathcal{L}(u, \mu) = u^\top V u - \mu(u^\top u - 1).$$

Condition du premier ordre

$$\nabla_u \mathcal{L} = 2Vu - 2\mu u = 0 \iff \boxed{Vu = \mu u.}$$

u est donc un vecteur propre de V associé à la valeur propre μ.

Valeur du critère : $u^\top V u = u^\top(\mu u) = \mu$.

Conclusion

Maximiser $u^\top V u$ sous $\|u\| = 1$ revient à choisir $\mu = \lambda_1$ (la plus grande valeur propre) et $u = u_1$ (vecteur propre dominant). C'est exactement le théorème de Courant-Fischer-Weyl.

Remarque (Axes suivants)

Les axes $u_2, \ldots, u_p$ se construisent de proche en proche en ajoutant la contrainte

3.4 — Composantes et axes principaux

Definition (Axe principal et composante principale)

- Le k-**ième axe principal** est le vecteur propre u_k de V associé à λ_k.
- La k-**ième composante principale** est la variable

$$\mathrm{c}_k = \mathrm{X}_c \mathrm{u}_k \in \mathbb{R}^n$$

c'est-à-dire la projection des individus sur l'axe u_k.

Proposition (Propriétés des composantes principales)

1. *Les* c_k *sont* ***centrées*** *:* $\bar{\mathrm{c}}_k = 0$.
2. *Leur variance est* $\mathrm{Var}(\mathrm{c}_k) = \lambda_k$.
3. *Elles sont* ***deux à deux non corrélées*** *:* $\mathrm{Cov}(\mathrm{c}_k, \mathrm{c}_l) = 0$ *si* $k \neq l$.
4. *L'inertie totale est conservée :* $\sum_{k=1}^{p} \lambda_k = \mathrm{Tr}(\mathrm{V})$.

Remarque

Les composantes principales fournissent un nouveau système de coordonnées **orthogonal** dans lequel

3.5 — ACP normée vs non normée

ACP non normée ($M = I_p$)

- On diagonalise V
- Inertie totale $= \mathrm{Tr}(V) = \sum_j s_j^2$
- Sensible aux unités
- Variable de plus grande variance domine

Quand l'utiliser ?

- Variables homogènes en unité
- Variances comparables
- Ex : intensités lumineuses, longueurs

ACP normée ($M = D_{1/s^2}$)

- On diagonalise R (corrélations)
- Inertie totale $= \mathrm{Tr}(R) = p$
- Adimensionnelle
- Toutes les variables ont poids égal

Quand l'utiliser ?

- Unités différentes
- Variances disparates
- Cas le plus courant en pratique

Conseil pratique

Si vous hésitez : **ACP normée**. Elle est plus robuste et plus interprétable, sauf cas particulier.

3.6 — Représentation des individus

Definition (Coordonnées factorielles des individus)

La coordonnée de l'individu i sur l'axe k est :

$$F_k(i) = c_{k,i} = \mathrm{x}_i^\top \mathrm{u}_k \quad \text{(produit scalaire avec l'axe).}$$

Plan factoriel (F_1, F_2)

- Chaque individu = un point $(F_1(i), F_2(i))$
- Distance dans le plan $\approx$ distance dans $\mathbb{R}^p$ si τ_2 élevé
- Position = profil de l'individu

Lecture

- Individus proches sur le plan $\rightarrow$ profils similaires
- Individus opposés $\rightarrow$ profils contrastés
- Individus centraux $\rightarrow$ profils moyens

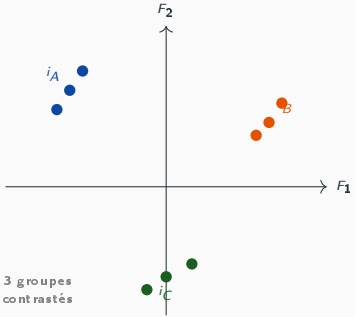

3.7 — Représentation des variables (cercle des corrélations)

Theorem (Coordonnées des variables)

Pour une ACP normée, la coordonnée de la variable x^j sur l'axe k est :

$$G_k(x^j) = \sqrt{\lambda_k}\, u_{kj} = \mathrm{Cor}(x^j, c_k).$$

Cercle des corrélations

Toutes les variables ont une norme ≤ 1 dans le plan factoriel :

$$G_1(x^j)^2 + G_2(x^j)^2 \leq 1.$$

On les représente à l'intérieur du cercle unité.

Lecture

- Variable proche du cercle $\rightarrow$ bien représentée
- Deux variables proches $\rightarrow$ corrélation positive
- Variables opposées $\rightarrow$ corrélation négative

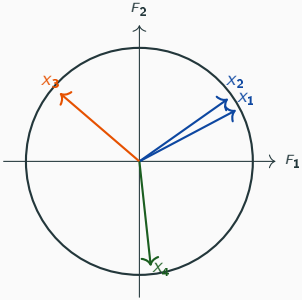

3.8 — Aides à l'interprétation : qualité et contributions

Definition (Qualité de représentation)

La **qualité de représentation** d'un individu i sur l'axe k est :

$$\cos_k^2(i) = \frac{F_k(i)^2}{\|\mathrm{x}_i - \mathrm{g}\|^2} \quad \in [0, 1].$$

Sur un plan : $\cos_{k,k'}^2(i) = \cos_k^2(i) + \cos_{k'}^2(i)$.

Definition (Contribution)

La **contribution** d'un individu i à l'inertie de l'axe k est :

$$\mathrm{ctr}_k(i) = \frac{p_i\, F_k(i)^2}{\lambda_k}, \qquad \sum_{i=1}^{n} \mathrm{ctr}_k(i) = 1.$$

Règles d'interprétation

- $\cos^2$ *élevé* $\rightarrow$ l'individu est bien représenté sur l'axe
- Contribution *élevée* $\rightarrow$ l'individu construit l'axe

3.9 — Variables et individus supplémentaires

Definition (Élément supplémentaire)

Un **individu (ou variable) supplémentaire** est une observation que l'on n'utilise pas pour construire les axes principaux, mais que l'on projette *a posteriori* sur le plan factoriel.

Individu supplémentaire x^*

$$F_k(\mathrm{x}^*) = (\mathrm{x}^* - \mathrm{g})^\top \mathrm{u}_k$$

On compare la position de x^* aux groupes existants.

Variable quantitative supp. x^{*j}

$$G_k(\mathrm{x}^{*j}) = \mathrm{Cor}(\mathrm{x}^{*j}, \mathrm{c}_k)$$

Position dans le cercle des corrélations.

Variable qualitative supp.

Pour chaque modalité m : barycentre des individus la possédant.

$$F_k(m) = \frac{1}{n_m} \sum_{i \in m} F_k(i)$$

Intérêts

- **Test** : prédire un nouvel individu
- **Validation** : positionner une variable connue
- **Interprétation** : caractériser les axes

3.10 — Combien d'axes retenir ?

Trois critères classiques

1. **Critère du coude** (*scree plot*) : repérer la cassure dans la courbe λ_k vs k.
2. **Critère de Kaiser** (ACP normée) : retenir les axes avec $\lambda_k \geq 1$ (plus que la variance moyenne).
3. **Critère de Karlis-Saporta-Spinaki** (KSS) : conserver $\lambda_k > 1 + 2\sqrt{(p-1)/(n-1)}$.

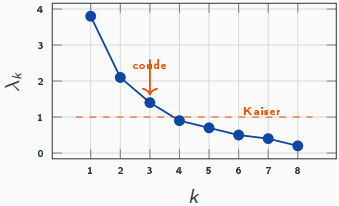

Critère pragmatique

Retenir le nombre d'axes pour atteindre un seuil de **variance cumulée** (typiquement 70–80%).

Méta-critère

Un axe doit toujours être interprétable sur le plan métier. Un axe non interprétable, même chargé en inertie, n'apporte rien.

3.11 — Workflow d'une ACP

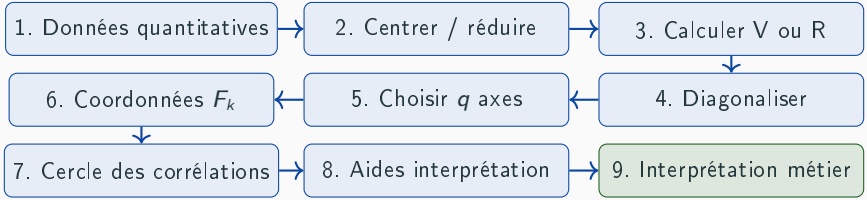

Sortie typique

Tableau des valeurs propres + scree plot → plan(s) factoriel(s) des individus + cercle(s) des corrélations → tableau ctr/cos^2 → commentaire.

3.12 — ACP avec FactoMineR et factoextra

```r
library(FactoMineR); library(factoextra)
data(decathlon)

# ACP normee (par defaut), 13e variable supplementaire qualitative
res <- PCA(decathlon, scale.unit = TRUE,
           quanti.sup = 11:12, quali.sup = 13, graph = FALSE)

# Valeurs propres et scree plot
get_eigenvalue(res)                # eigenvalue, % var, cumul
fviz_eig(res, addlabels = TRUE)    # scree plot

# Plan factoriel des individus
fviz_pca_ind(res, col.ind = "cos2", repel = TRUE,
             gradient.cols = c("blue", "red"))

# Cercle des correlations
fviz_pca_var(res, col.var = "contrib",
             gradient.cols = c("grey", "orange", "red"))

# Biplot
fviz_pca_biplot(res, habillage = 13, repel = TRUE)

# Tableau qualite et contributions
res$ind$cos2[, 1:2]
```

3.13 — Récapitulatif du chapitre

À retenir

- ACP = diagonalisation de V (ou R) pour décomposer l'inertie
- Axes principaux = vecteurs propres (u_k)
- Composantes = projections ($c_k = X_c u_k$)
- Variances = valeurs propres (λ_k)
- Composantes décorrélées et ordonnées par inertie
- Cercle des corrélations : visualiser les variables
- Aides : $\cos^2$, contributions, supplémentaires

Garanties théoriques

- Eckart-Young $\Rightarrow$ ACP optimale
- Composantes orthogonales $\Rightarrow$ décorrélation
- Conservation de l'inertie totale

Limites

ACP suppose des relations linéaires entre variables quantitatives. Pour des données qualitatives ou des relations non linéaires, voir AFC (chap. 4) ou Kernel PCA.

Analyse Factorielle des Correspondances (AFC)

4.1 — Pourquoi l'AFC ?

Données : table de contingence $\mathrm{N} = (n_{ij}) \in \mathbb{N}^{I \times J}$ croisant deux variables qualitatives.

Objectifs

1. Décrire les associations entre modalités lignes et colonnes
2. Tester / quantifier l'**écart à l'indépendance**
3. Représenter **simultanément** lignes et colonnes sur un plan factoriel

Origine : Benzécri (1973), école française. **AFC** = ACP *généralisée* avec :

- Tableau de profils
- Métrique du χ^2

CSP × **Diplôme** (INSEE)

	Bac	Lic.	Mast.	Doct.	total
Cadre	12	65	180	95	352
ProfInt	88	110	50	5	253
Employé	230	45	12	1	288
Ouvrier	195	8	2	0	205
total	525	228	244	101	1098

Question

Quels diplômes sont *associés* à quelles CSP ?

4.2 — Profils lignes et profils colonnes

Definition (Tableau de fréquences relatives)

$$f_{ij} = \frac{n_{ij}}{n}, \qquad f_{i\bullet} = \sum_j f_{ij}, \qquad f_{\bullet j} = \sum_i f_{ij}$$

où $n = \sum_{i,j} n_{ij}$ est l'effectif total.

Definition (Profil ligne, profil colonne)

- **Profil de la ligne** i : $\mathrm{L}_i = \left(\frac{f_{i1}}{f_{i\bullet}}, \ldots, \frac{f_{iJ}}{f_{i\bullet}}\right) \in \mathbb{R}^J$
- **Profil de la colonne** j : $\mathrm{C}_j = \left(\frac{f_{1j}}{f_{\bullet j}}, \ldots, \frac{f_{Ij}}{f_{\bullet j}}\right) \in \mathbb{R}^I$

Chaque profil est une distribution conditionnelle (somme $= 1$).

Remarque (Profil moyen)

Le **profil moyen ligne** est $(f_{\bullet 1}, \ldots, f_{\bullet J})$ (la marge colonne). Sous l'**indépendance** χ^2, tous les profils lignes seraient égaux à ce profil moyen.

4.3 — Distance du χ^2

Definition (Distance du χ^2 entre profils lignes)

$$d^2_{\chi^2}(\mathsf{L}_i, \mathsf{L}_{i'}) = \sum_{j=1}^{J} \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - \frac{f_{i'j}}{f_{i'\bullet}} \right)^2 .$$

C'est une distance euclidienne dans $\mathbb{R}^J$ avec métrique $\mathsf{M} = \mathsf{D}_{1/f_{\bullet j}}$ (inverses des fréquences marginales).

Proposition (Propriétés essentielles)

1. ***Pondération*** *: les colonnes rares pèsent plus lourd* $(1/f_{\bullet j})$.
2. ***Équivalence distributionnelle*** *: si deux colonnes sont proportionnelles, leur fusion ne change pas les distances entre lignes.*
3. ***Symétrie*** *: on définit de même la distance entre profils colonnes avec* $\mathsf{M} = \mathsf{D}_{1/f_{i\bullet}}$.

Remarque

La métrique du χ^2 équilibre l'influence des modalités peu fréquentes mais informatives.

4.4 — Test d'indépendance et inertie totale

Hypothèse d'indépendance : $f_{ij} = f_{i\bullet}\, f_{\bullet j}$.

Theorem (Statistique du χ^2 et inertie)

La statistique de Pearson est :

$$\chi^2 = n \sum_{i,j} \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet} f_{\bullet j}} = n\,\Phi^2.$$

Le coefficient $\Phi^2 = \chi^2/n$ est exactement l'inertie totale du nuage des profils lignes (ou colonnes), pondérés par leurs marges :

$$\boxed{I_{totale} = \sum_{i=1}^{I} f_{i\bullet}\, d^2_{\chi^2}(\mathsf{L}_i, \mathsf{L}_\bullet) = \Phi^2 = \chi^2/n.}$$

Remarque (Conséquence)

L'AFC *décompose* la statistique du χ^2 : chaque axe factoriel explique une part de l'écart à

4.5 — Formulation comme SVD généralisée

Tableau centré : $\widetilde{f_{ij}} = f_{ij} - f_{i\bullet} f_{\bullet j}$.

Theorem (Diagonalisation)

Soit S *la matrice de terme général* $\widetilde{f_{ij}}/\sqrt{f_{i\bullet} f_{\bullet j}}$. *La SVD* $\mathrm{S} = \mathrm{U} \circ \mathrm{V}^\top$ *fournit les axes principaux de l'AFC :*

- *Valeurs propres :* $\lambda_k = \sigma_k^2$ *(vérifient* $\lambda_k \leq 1$*)*
- *Inertie totale :* $\Phi^2 = \sum_k \lambda_k$
- *Axes des lignes :* $\mathrm{D}_{1/\sqrt{f_{i\bullet}}}\mathrm{U}$
- *Axes des colonnes :* $\mathrm{D}_{1/\sqrt{f_{\bullet j}}}\mathrm{V}$

Cadre unificateur

AFC = ACP du triplet $(\mathrm{X}, \mathrm{M}, \mathrm{D}_p)$ avec :

- X = tableau des profils lignes
- $\mathrm{M} = \mathrm{D}_{1/f_{\bullet j}}$ (métrique χ^2)

4.6 — Coordonnées factorielles

Definition (Coordonnées des lignes et des colonnes)

Sur le k-ième axe, les coordonnées sont :

$$F_k(i) \quad \text{(coordonnée de la ligne } i\text{)}, \qquad G_k(j) \quad \text{(coordonnée de la colonne } j\text{)}.$$

Theorem (Inertie expliquée par axe)

$$\sum_{i=1}^{I} f_{i\bullet}\, F_k(i)^2 = \lambda_k, \qquad \sum_{j=1}^{J} f_{\bullet j}\, G_k(j)^2 = \lambda_k.$$

Lignes et colonnes contribuent ensemble à la même inertie λ_k.

Remarque (Double point de vue)

L'AFC traite symétriquement lignes et colonnes : on diagonalise deux matrices semblables qui partagent les mêmes valeurs propres non nulles (dualité). C'est ce qui justifie la **représentation simultanée**.

4.7 — Formules barycentriques (transition)

Theorem (Relations de transition)

Pour tout axe k et avec λ_k la valeur propre associée :

$$\boxed{F_k(i) = \frac{1}{\sqrt{\lambda_k}} \sum_{j=1}^{J} \frac{f_{ij}}{f_{i\bullet}} G_k(j), \qquad G_k(j) = \frac{1}{\sqrt{\lambda_k}} \sum_{i=1}^{I} \frac{f_{ij}}{f_{\bullet j}} F_k(i).}$$

Lecture barycentrique

La position d'une ligne i est, à un facteur près, le barycentre des positions des colonnes j pondérées par son profil $f_{ij}/f_{i\bullet}$. Et inversement.

Remarque (Interprétation graphique)

Une modalité ligne et une modalité colonne proches sur le plan factoriel sont dans une **relation d'attraction** : leur fréquence conjointe dépasse l'attendu sous indépendance.

4.8 — Représentation simultanée

Biplot AFC

Sur le *même* plan, on représente :

- les modalités lignes (I points)
- les modalités colonnes (J points)

Règles de lecture

- Deux *lignes* proches : profils similaires
- Deux *colonnes* proches : profils similaires
- Ligne $\times$ colonne proche : association forte
- Origine = profil moyen (proche = proche de l'indépendance)

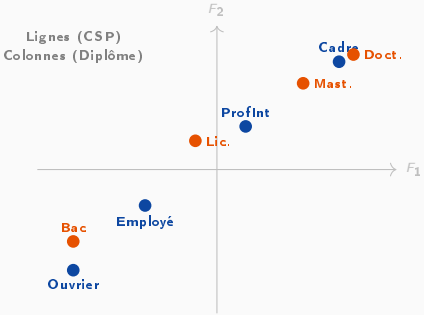

4.9 — Aides à l'interprétation

Definition (Qualité de représentation et contributions)

Pour la ligne i sur l'axe k :

$$\cos_k^2(i) = \frac{F_k(i)^2}{\sum_{l\geq 1} F_l(i)^2}, \qquad \mathrm{ctr}_k(i) = \frac{f_{i\bullet} F_k(i)^2}{\lambda_k}.$$

Définitions analogues pour les colonnes.

Règles de lecture

- Contribution élevée : la modalité *construit* l'axe (seuil pratique : ctr $> 1/I$ ou $1/J$)
- $\cos^2$ élevé : la modalité est *bien représentée*
- Une modalité avec $\cos^2$ faible doit être interprétée avec prudence

Remarque

On peut décomposer le χ^2 en sommes par cellule (**contribution au** χ^2) :
$\chi^2_{ij} = n \cdot (f_{ij} - f_{i\bullet} f_{\bullet j})^2 / (f_{i\bullet} f_{\bullet j})$, ce qui complète l'AFC.

4.10 — Reconstitution et approximation

Theorem (Formule de reconstitution)

Le tableau de fréquences peut être reconstruit à partir des r axes principaux :

$$f_{ij} = f_{i\bullet} f_{\bullet j} \left(1 + \sum_{k=1}^{r} \frac{F_k(i)\, G_k(j)}{\sqrt{\lambda_k}} \right).$$

Lecture

- Le terme $f_{i\bullet} f_{\bullet j}$ est l'indépendance théorique.
- La somme corrective décompose les écarts à l'indépendance par axe.
- Tronquer la somme à $q < r$ axes donne la **meilleure approximation de rang** q (Eckart-Young).

Remarque (Comparaison à l'ACP)

AFC et ACP partagent la même structure : SVD généralisée + Eckart-Young. La différence est uniquement dans le *triplet* $(\mathrm{X}, \mathrm{M}, \mathrm{D}_p)$.

4.11 — Modalités et tableaux supplémentaires

Modalité supplémentaire : projetée sur les axes *après* construction, sans contribuer à leur calcul.

Formules de projection

Pour une ligne supplémentaire i^* de profil L_{i^*} :

$$F_k(i^*) = \frac{1}{\sqrt{\lambda_k}} \sum_{j=1}^{J} \frac{f_{i^*j}}{f_{i^*\bullet}} G_k(j).$$

Symétriquement pour une colonne supplémentaire.

Cas d'usage

- Comparer un échantillon test à une population de référence
- Suivre une modalité dans le temps (cohorte)
- Caractériser un axe par une variable externe

Attention

Une modalité supplémentaire *rare* ($f \to 0$) peut être très mal positionnée : on l'interprète avec son $\cos^2$.

4.12 — AFC avec FactoMineR (et ca)

```r
library(FactoMineR); library(factoextra)

# Tableau de contingence (CSP x Diplome)
tab <- as.table(rbind(
  Cadre   = c(Bac=12,  Lic=65,  Mast=180, Doct=95),
  ProfInt = c(Bac=88,  Lic=110, Mast=50,  Doct=5),
  Employe = c(Bac=230, Lic=45,  Mast=12,  Doct=1),
  Ouvrier = c(Bac=195, Lic=8,   Mast=2,   Doct=0)))

# Test d'independance du chi2
chisq.test(tab)

# Analyse Factorielle des Correspondances
res <- CA(tab, graph = FALSE)

# Valeurs propres et inertie
get_eigenvalue(res)                # lambda_k, % d'inertie
fviz_eig(res, addlabels = TRUE)    # scree plot

# Representation simultanee (biplot)
fviz_ca_biplot(res, repel = TRUE)

# cos2 et contributions
res$row$cos2; res$col$cos2
```

4.13 — Récapitulatif du chapitre

À retenir

- AFC = ACP des profils avec métrique χ^2
- Inertie totale $\Phi^2 = \chi^2/n$
- Lignes et colonnes : mêmes valeurs propres
- Représentation simultanée sur un biplot
- Formules de transition $\Rightarrow$ lecture barycentrique
- Reconstitution comme *somme* d'écarts à l'indépendance

Garanties théoriques

- SVD généralisée : optimalité (Eckart-Young)
- Conservation de l'inertie totale
- Décomposition orthogonale du χ^2

Domaine d'application

AFC $\rightarrow$ 2 variables qualitatives. Pour $p > 2$ variables qualitatives, on utilise l'**ACM** (Analyse des Correspondances Multiples), chap. 5.

Analyse des Correspondances Multiples (ACM)

5.1 — Pourquoi l'ACM ?

Données : n individus décrits par p variables qualitatives $X^1, \ldots, X^p$, chaque variable ayant K_j modalités.

Notons $K = K_1 + \cdots + K_p$ le **nombre total de modalités**.

Cas typiques

- Enquêtes (sociologiques, marketing)
- Questionnaires à choix multiple
- Observations binaires (présence / absence)

Limite de l'AFC : ne traite que *deux* variables.
ACM : généralise à p variables qualitatives.

Exemple : enquête

indiv.	Sexe	Âge	Diplôme
i_1	H	30-50	Master
i_2	F	18-29	Lic.
i_3	H	50+	Doct.
i_4	F	30-50	Bac
$\vdots$	$\vdots$	$\vdots$	$\vdots$

Question

Quelles sont les associations entre toutes les modalités ?

5.2 — Tableau Disjonctif Complet (TDC)

Definition (TDC)

Le **tableau disjonctif complet** $Z \in \{0,1\}^{n \times K}$ code chaque individu par un vecteur indicateur :

$$z_{im} = \begin{cases} 1 & \text{si l'individu } i \text{ possède la modalité } m \\ 0 & \text{sinon.} \end{cases}$$

Pour chaque variable X^j, $\sum_{m \in X^j} z_{im} = 1$ (un et un seul 1 par variable).

Marges du TDC

- Marge ligne : $z_{i\bullet} = p$ (chaque individu coche p modalités)
- Marge colonne : $z_{\bullet m} = n_m$ (effectif de la modalité m)
- Total : $z_{\bullet\bullet} = np$

TDC sur 3 variables

	H	F	18-29	30-50	50+	Bac	Li
i_1	1	0	0	1	0	0	
i_2	0	1	1	0	0	0	
i_3	1	0	0	0	1	0	
i_4	0	1	0	1	0	1	

Fréquences relatives

5.3 — Définition par AFC du TDC

Definition (ACM)

L'**Analyse des Correspondances Multiples** de p variables qualitatives est l'**AFC** du tableau disjonctif complet Z.

Propriétés héritées de l'AFC

- Représentation simultanée des individus et des modalités
- Métrique du χ^2 sur les modalités
- Formules de transition (barycentriques)
- Décomposition d'inertie via SVD généralisée

Theorem (Inertie totale en ACM)

$$I_{totale} = \frac{K}{p} - 1 = \frac{1}{p}\sum_{j=1}^{p}(K_j - 1).$$

*L'inertie ne dépend que du **nombre de modalités** (et pas des liaisons entre variables) : limitation majeure du critère de pourcentage d'inertie.*

5.4 — Tableau de Burt

Definition (Tableau de Burt)

Le **tableau de Burt** $B = Z^\top Z \in \mathbb{N}^{K \times K}$ croise toutes les modalités deux à deux.

- Bloc diagonal (j, j) : matrice diagonale des effectifs de X^j
- Bloc (j, j') pour $j \neq j'$: table de contingence des deux variables

Theorem (Lien entre AFC du TDC et AFC de Burt)

Soient λ_k^Z les valeurs propres de l'AFC du TDC et λ_k^B celles de l'AFC du tableau de Burt. Alors :

$$\lambda_k^B = (\lambda_k^Z)^2.$$

Les axes principaux sont identiques. Les valeurs propres de Burt ***contrastent*** *mieux : critère de Benzécri pour réajuster les pourcentages d'inertie.*

Correction de Benzécri

Seules les valeurs propres $\lambda_k > 1/p$ sont significatives. La part d'inertie corrigée est :
$\tau_k^c = (\lambda_k - 1/p)^2 / \sum_{l:\lambda_l > 1/p} (\lambda_l - 1/p)^2$.

5.5 — Coordonnées des modalités et des individus

Theorem (Coordonnées d'une modalité)

La coordonnée de la modalité m sur l'axe k est, à un facteur près, le barycentre des coordonnées des individus la possédant :

$$G_k(m) = \frac{1}{\sqrt{\lambda_k}} \cdot \frac{1}{n_m} \sum_{i : z_{im} = 1} F_k(i).$$

Theorem (Coordonnées d'un individu)

Symétriquement, la coordonnée d'un individu i est le barycentre des coordonnées des modalités qu'il possède :

$$F_k(i) = \frac{1}{\sqrt{\lambda_k}} \cdot \frac{1}{p} \sum_{m : z_{im} = 1} G_k(m).$$

Remarque

Ces **relations barycentriques** (dites de *transition*) sont exactement celles de l'AFC, appliquées au TDC. Elles fondent la représentation simultanée individus / modalités.

5.6 — Représentation simultanée

Plan factoriel ACM

On représente sur le *même* plan :

- les n individus (gros nuage)
- les K modalités (peu nombreuses)

Lecture

- Une modalité m est au barycentre de ses individus
- Modalités proches → associations fortes
- Modalités opposées → profils contrastés
- Modalités à l'origine → proches du profil moyen

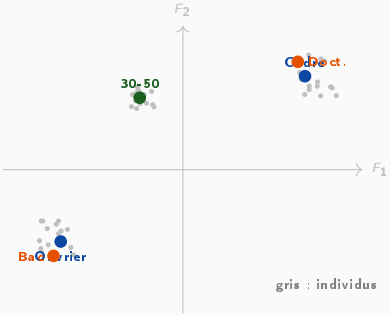

5.7 — Aides à l'interprétation

Definition (Indicateurs pour les modalités)

Pour la modalité m (de fréquence $f_m = n_m/(np)$) sur l'axe k :

$$\mathrm{ctr}_k(m) = \frac{f_m\, G_k(m)^2}{\lambda_k}, \qquad \cos_k^2(m) = \frac{G_k(m)^2}{d^2_{\chi^2}(m,0)}.$$

Distance d'une modalité à l'origine

$$d^2_{\chi^2}(m,0) = \frac{1}{f_m} - 1 = \frac{n_m^{-1} \cdot np - 1}{1} \quad \Rightarrow \quad \text{distance } \textit{grande} \text{ pour modalités } \textit{rares}.$$

Remarque (Influence des modalités rares)

Une modalité rare (peu d'individus la possèdent) est *loin* de l'origine et a souvent une forte contribution. C'est un piège classique : on regroupera les modalités d'effectif inférieur à $\sim 5\%$ de n.

5.8 — Variables et individus supplémentaires

Variable supplémentaire qualitative : on projette ses modalités *a posteriori*, sans contribuer à la construction des axes.

$$G_k(m_{\text{sup}}) = \frac{1}{\sqrt{\lambda_k}} \cdot \frac{1}{n_{m_{\text{sup}}}} \sum_{i : z_{im_{\text{sup}}} = 1} F_k(i).$$

Variable supplémentaire quantitative : on calcule les corrélations avec chaque composante factorielle :

$$\eta^2(\mathrm{x}^{\text{sup}}, F_k) \quad \text{(rapport de corrélation)}.$$

Individu supplémentaire

Vecteur indicateur z_{i^*}, projeté via la formule de transition.

Cas d'usage

Variables descriptives *externes* (cible métier, segment client) projetées sur la structure latente.

5.9 — Lien avec l'ACP via le codage disjonctif

Theorem (ACM comme ACP particulière)

*L'ACM est l'**ACP non normée** du tableau disjonctif complet **centré-réduit** avec :*

- *métrique* $\mathrm{M} = \frac{n}{p}\mathrm{D}_{1/n_m}$ *sur les modalités*
- *pondération* $\mathrm{D}_p = \frac{1}{n}\mathrm{I}_n$ *sur les individus*

Comparaison méthodologique

	ACP	AFC	ACM
Données	quantitatives	1 contingence	qualitatives
Métrique	I ou D_{1/s^2}	$\mathrm{D}_{1/f_{\bullet j}}$	$\frac{n}{p}\mathrm{D}_{1/n_m}$
Inertie tot.	Tr(V) ou p	$\Phi^2 = \chi^2/n$	$K/p - 1$
λ_k	libres	≤ 1	≤ 1

Remarque

Tous les chapitres précédents (ACP, AFC, ACM) reposent sur la **même machine algébrique** : la SVD généralisée du Ch. 2.

5.10 — Stratégie pratique en ACM

Trois précautions à prendre

1. **Regrouper les modalités rares** ($n_m < 5\%$ de n) : elles contribuent excessivement aux axes.
2. **Variables très liées** : leurs modalités créent un effet de *grappe* (*Guttman*). Choisir des variables à information complémentaire.
3. **Recourir au tableau de Burt** : valeurs propres mieux contrastées, correction de Benzécri pour les pourcentages d'inertie.

Workflow ACM type

1. Description univariée et bivariée (effectifs, χ^2 par paire)
2. Recodage / regroupement
3. ACM sur le TDC (variables actives + supplémentaires)
4. Interprétation des axes (modalités $\cos^2$ élevés et ctr fortes)
5. Classification des individus (CAH sur les coordonnées factorielles)

5.11 — ACM avec FactoMineR

```r
library(FactoMineR); library(factoextra)
data(tea)         # 300 individus x 36 variables qualitatives

# Selection des variables actives (qualitatives)
actives <- c("breakfast","tea.time","evening","lunch","dinner",
             "always","resto","pub","tearoom",
             "How","how","sugar","where","price")

# ACM
res <- MCA(tea, quanti.sup = 19, quali.sup = c(20:36),
           graph = FALSE, ncp = 5)

# Valeurs propres et eboulis
get_eigenvalue(res)
fviz_screeplot(res, addlabels = TRUE)

# Plan factoriel des modalites
fviz_mca_var(res, repel = TRUE, col.var = "contrib",
             gradient.cols = c("blue","red"))

# Plan factoriel des individus
fviz_mca_ind(res, label = "none", habillage = "Tea")

# Biplot (modalites + individus)
```

5.12 — Récapitulatif du chapitre

À retenir

- ACM = AFC du tableau disjonctif complet
- p variables qualitatives, K modalités totales
- Inertie totale $K/p - 1$: indépendante des liaisons
- Valeurs propres $\lambda_k \leq 1$
- Tableau de Burt $\mathrm{B} = \mathrm{Z}^\top \mathrm{Z}$: $\lambda_k^B = (\lambda_k^Z)^2$
- Représentation simultanée individus + modalités
- Relations barycentriques (transition)

Garanties théoriques

- ACP/AFC/ACM : même cadre SVD généralisée
- Optimalité par Eckart-Young
- Décomposition orthogonale d'inertie

Pièges à éviter

Modalités rares, variables redondantes, effet Guttman, ne pas oublier la correction de Benzécri pour interpréter les % d'inertie.

Classification

6.1 — Classification (clustering)

Definition (Classification non supervisée)

La **classification** d'un nuage $\mathcal{N} = \{x_i\}_{i=1}^n$ vise à construire une **partition** $\mathcal{C} = \{\mathcal{C}_1, \ldots, \mathcal{C}_K\}$ ou une **hiérarchie** de partitions emboîtées telles que :

- les individus d'une même classe sont semblables
- les classes sont distinctes entre elles

Deux familles principales

- **Partition directe** : K fixé a priori → k-means, k-medoïdes, modèles de mélange
- **Hiérarchique** : produit un dendrogramme → CAH ascendante, divisive

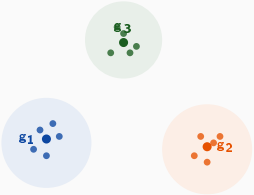

Critère unificateur (Huygens)

$$I_{\text{tot}} = I_{\text{intra}} + I_{\text{inter}}.$$

Minimiser $I_{\text{intra}} \Leftrightarrow$ maximiser I_{inter}.

6.2 — Algorithme k-means

Definition (Critère k-means)

Étant donné K fixé, on cherche $\mathcal{C} = (\mathcal{C}_1, \ldots, \mathcal{C}_K)$ minimisant :

$$W(\mathcal{C}) = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} \|\mathrm{x}_i - \mathrm{g}_k\|^2, \qquad \mathrm{g}_k = \frac{1}{|\mathcal{C}_k|} \sum_{i \in \mathcal{C}_k} \mathrm{x}_i.$$

$W(\mathcal{C}) = n\, I_{\text{intra}}$: minimiser W revient à minimiser l'inertie intra-classe.

Algorithme de Lloyd (1957)

1. Initialiser K centres $\mathrm{g}_1^{(0)}, \ldots, \mathrm{g}_K^{(0)}$
2. **Affectation** : $\mathcal{C}_k^{(t)} = \{i : k = \arg\min_l \|\mathrm{x}_i - \mathrm{g}_l^{(t)}\|^2\}$
3. **Mise à jour** : $\mathrm{g}_k^{(t+1)} = \frac{1}{|\mathcal{C}_k^{(t)}|} \sum_{i \in \mathcal{C}_k^{(t)}} \mathrm{x}_i$
4. Répéter 2-3 jusqu'à stabilité de $\mathcal{C}$

Theorem (Convergence)

*La suite $\left(W(\mathcal{C}^{(t)})\right)_t$ est **décroissante minorée** par 0, elle converge donc en un nombre fini d'itérations vers un minimum local de W.*

6.3 — k-means : sensibilité à l'initialisation

Limites du k-means

- Solution non globale : dépend de l'initialisation
- Hypothèse implicite : classes sphériques, taille comparable
- Sensible aux **outliers** (médiane $\rightarrow$ k-medoïdes)
- Métrique euclidienne : suppose des variables comparables

Stratégies d'initialisation

1. **Aléatoire** (re-démarrer plusieurs fois et garder le meilleur W)
2. **k-means++** (Arthur & Vassilvitskii, 2007) : choisir successivement les centres avec une probabilité proportionnelle au carré de la distance au plus proche centre. Garantit $\mathbb{E}[W] \leq 8(\ln K + 2) \cdot W^*$.
3. **Initialisation par CAH** : couper l'arbre à K classes, utiliser leurs centres comme initialisation $\rightarrow$ approche *HCPC*.

Remarque

Le choix de K se fait par scree-plot de l'inertie intra, silhouette, ou critère de Calinski-Harabasz.

6.4 — Classification Ascendante Hiérarchique (CAH)

Definition (CAH agglomérative)

On part de la partition triviale en n classes singletons. À chaque étape, on fusionne les deux classes les plus proches selon une **stratégie de regroupement** (*linkage*) δ, jusqu'à obtenir une seule classe.

Données produites par la CAH

- Une suite de $n-1$ fusions (objet `merge`)
- Les hauteurs de fusion (objet `height`)
- Un dendrogramme : arbre représentant les emboîtements

Avantages

- Aucune contrainte sur K (choisi *a posteriori*)
- Fournit toute une *hiérarchie* de partitions
- Permet une lecture visuelle (dendrogramme)

Remarque

Inconvénient : complexité $O(n^2 \log n)$ en général, $O(n^3)$ avec lien Ward sans optimisation. Limite

6.5 — Critères de linkage

Definition (Quatre stratégies classiques)

Pour deux classes A, B :

- **Single** (saut min) : $\delta(A, B) = \min_{i \in A, j \in B} d(\mathrm{x}_i, \mathrm{x}_j)$
- **Complete** (saut max) : $\delta(A, B) = \max_{i \in A, j \in B} d(\mathrm{x}_i, \mathrm{x}_j)$
- **Average** (moyenne) : $\delta(A, B) = \frac{1}{|A||B|} \sum_{i \in A, j \in B} d(\mathrm{x}_i, \mathrm{x}_j)$
- **Ward** (inertie) : voir slide suivant

Comparaison qualitative

Linkage	Tendance	Effet
Single	chaînage	classes très allongées
Complete	compact	classes sphériques, moyennes
Average	équilibré	moyennes, sensible aux outliers
Ward	inertie	classes compactes et nombre comparable

Remarque

Recommandation : Ward est le standard en analyse des données (critère cohérent avec les méthodes

6.6 — Méthode de Ward

Definition (Indice de Ward)

La distance de Ward entre deux classes A, B est :

$$\delta_{\text{Ward}}(A, B) = \frac{|A|\,|B|}{|A| + |B|}\, d^2(\mathrm{g}_A, \mathrm{g}_B).$$

Theorem (Interprétation : perte d'inertie inter)

La fusion de A et B augmente l'inertie intra-classe de $\delta_{Ward}(A, B)$. Symétriquement elle diminue l'inertie inter-classe du même montant.

Idée du Ward

À chaque étape, on fusionne les deux classes dont la fusion **minimise la perte d'inertie inter**. C'est le critère le plus naturel au regard du théorème de Huygens.

Remarque (Lien avec k-means)

Le Ward et le k-means partagent le *même* critère (minimiser I_{intra}). Le Ward est une optimisation **gloutonne hiérarchique**, k-means une optimisation **itérative** avec K fixé.

6.7 — Dendrogramme et coupure

Lecture du dendrogramme

- Hauteur d'un nœud = valeur du critère δ à la fusion
- En Ward : hauteur = saut d'inertie inter-classe
- Une partition en K classes = coupure horizontale qui traverse K branches

Choix du nombre de classes

- Repérer le plus grand saut dans la suite des hauteurs
- Compromis entre nombre de classes *interprétables* et compacité
- Critères : silhouette, indice de Calinski-Harabasz, gap statistic

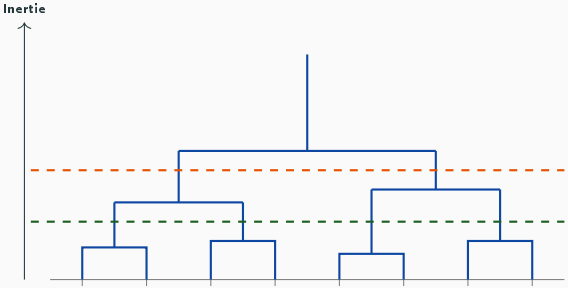

6.8 — Couplage avec ACP / AFC / ACM

Theorem (HCPC : Hierarchical Clustering on Principal Components)

Procédure *: appliquer la classification (CAH ou k-means) sur les premières coordonnées factorielles* $(F_1, \ldots, F_q)$ *d'une ACP/AFC/ACM plutôt que sur les variables d'origine.*

Avantages méthodologiques

- Débruitage : on retient l'inertie principale
- Décorrélation : composantes orthogonales
- Homogénéité d'échelle (composantes standardisées)
- Compatibilité avec données qualitatives via ACM

Algorithme HCPC (FactoMineR)

1. ACP / AFC / ACM
2. Choix de q axes (par défaut auto)
3. CAH-Ward sur $(F_1, \ldots, F_q)$
4. Coupure automatique au plus grand saut
5. Consolidation par k-means (option)
6. Caractérisation des classes

Remarque

Le HCPC est la méthode standard en analyse des données françaises : il combine la *description* factorielle et la *typologie*.

6.9 — Caractérisation des classes

Definition (Valeur-test pour une variable continue)

Pour une variable X^j, la **valeur-test** associée à la classe $\mathcal{C}_k$ est :

$$v_{kj} = \frac{\bar{X}_k^j - \bar{X}^j}{\sqrt{s_j^2/n_k \cdot (n - n_k)/(n-1)}} \quad \approx \mathcal{N}(0,1) \text{ sous } H_0.$$

Lecture

- $|v_{kj}| > 2$: la classe $\mathcal{C}_k$ est significativement différente de la moyenne globale sur X^j
- $v_{kj} > 0$: la classe a une moyenne *supérieure*
- $v_{kj} < 0$: moyenne *inférieure*

Variables qualitatives

On utilise un test de proportion (loi hypergéométrique) entre la fréquence d'une modalité dans $\mathcal{C}_k$ et dans la population totale.

Remarque

6.10 — Évaluation et validation

Indices internes

- **Inertie expliquée** : $I_{\text{inter}}/I_{\text{tot}} \in [0, 1]$
- **Silhouette** (Rousseeuw, 1987)

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad \bar{s} = \frac{1}{n}\sum_i s(i) \in [-1, 1]$$

  avec $a(i)$: distance moyenne intra et $b(i)$: distance moyenne au cluster voisin le plus proche.
- **Calinski-Harabasz** : $\text{CH} = \frac{I_{\text{inter}}/(K-1)}{I_{\text{intra}}/(n-K)}$

Stabilité (bootstrap)

Tirer plusieurs échantillons bootstrap, refaire la classification, mesurer la proportion d'individus toujours regroupés.

Il n'existe pas de vérité unique

La classification est exploratoire. Plusieurs partitions peuvent être pertinentes selon les questions métier. Toujours valider avec un expert du domaine.

6.11 — Classification avec R

```r
library(FactoMineR); library(factoextra); library(cluster)
data(decathlon)

# 1) ACP (10 variables actives, 11-12 quanti.sup, 13 quali.sup)
res.pca <- PCA(decathlon, scale.unit = TRUE,
               quanti.sup = 11:12, quali.sup = 13, graph = FALSE)

# 2) HCPC : CAH + consolidation k-means sur les composantes
res.hcpc <- HCPC(res.pca, nb.clust = -1, consol = TRUE, graph = FALSE)
plot(res.hcpc, choice = "tree")      # dendrogramme
plot(res.hcpc, choice = "map")       # individus colories par classe
res.hcpc$desc.var                     # caracterisation par variables
res.hcpc$desc.axes                    # caracterisation par axes
res.hcpc$desc.ind                     # paragons (individus typiques)

# 3) k-means seul (sur donnees reduites)
X <- scale(decathlon[, 1:10])
km <- kmeans(X, centers = 4, nstart = 50)
fviz_cluster(km, data = X, ellipse.type = "convex")

# 4) Silhouette
sil <- silhouette(km$cluster, dist(X))
fviz_silhouette(sil)
```

6.12 — Récapitulatif du chapitre

À retenir

- Critère unificateur : minimiser I_{intra} (Huygens)
- **k-means** : itératif, K fixé, convergence locale
- **CAH** : agglomératif, dendrogramme, K a posteriori
- **Ward** = critère d'inertie, standard de l'AD française
- **HCPC** : classification sur composantes factorielles
- Caractérisation par valeur-test et variables descriptives
- Évaluation : silhouette, CH, stabilité bootstrap

Lien avec le reste du cours

- Théorème de Huygens (Ch. 1) : critère
- ACP/AFC/ACM (Ch. 3-5) : préparation du nuage
- AFD (Ch. 7) : version supervisée

Choix méthodologique

HCPC (ACP + Ward + k-means) reste la méthode de référence en analyse des données françaises pour produire une typologie validée et interprétable.

Analyse Factorielle Discriminante (AFD)

7.1 — De la description à la discrimination

Cadre : on dispose d'un tableau $X \in \mathbb{R}^{n \times p}$ quantitatif et d'une variable qualitative $Y \in \{1, \ldots, K\}$ définissant K groupes.

Deux objectifs (versants de l'AFD)

1. **Descriptif** : construire des combinaisons linéaires de X maximisant la séparation des K groupes.
2. **Décisionnel** : à partir d'une nouvelle observation, prédire son groupe (classification supervisée).

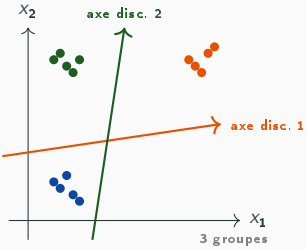

Pont entre AD et ML

- Côté analyse des données : AFD descriptive (Fisher 1936)
- Côté ML supervisé : LDA (Linear Discriminant Analysis)

7.2 — Décomposition de la variance (Huygens)

On note $n_k = |\mathcal{C}_k|$, $\mathrm{g}_k = \frac{1}{n_k}\sum_{i\in\mathcal{C}_k} \mathrm{x}_i$ et $\mathrm{g} = \frac{1}{n}\sum_i \mathrm{x}_i$.

Theorem (Décomposition de la matrice de variance-covariance)

La matrice V *se décompose en une partie inter-groupes (between) et une partie intra-groupes (within) :*

$$\boxed{\mathrm{V} = \mathrm{B} + \mathrm{W}}$$

avec

$$\mathrm{B} = \frac{1}{n}\sum_{k=1}^{K} n_k(\mathrm{g}_k - \mathrm{g})(\mathrm{g}_k - \mathrm{g})^\top, \quad \mathrm{W} = \frac{1}{n}\sum_{k=1}^{K}\sum_{i\in\mathcal{C}_k}(\mathrm{x}_i - \mathrm{g}_k)(\mathrm{x}_i - \mathrm{g}_k)^\top.$$

Remarque (Lien avec Huygens)

Prendre la trace : $\mathrm{Tr}(\mathrm{V}) = \mathrm{Tr}(\mathrm{B}) + \mathrm{Tr}(\mathrm{W})$, soit $I_{\mathrm{tot}} = I_{\mathrm{inter}} + I_{\mathrm{intra}}$.

Vocabulaire

B *(between)* mesure l'écart entre groupes, W *(within)* mesure la variabilité à l'intérieur des groupes.

7.3 — Critère de Fisher

Definition (Critère de Fisher)

Pour un axe $u \in \mathbb{R}^p$, le **rapport de Fisher** est

$$J(u) = \frac{u^\top B u}{u^\top W u} \quad \in \mathbb{R}^+.$$

On cherche les directions u maximisant J : axes discriminants.

Interprétation

- Numérateur : variance inter-groupes sur l'axe u
- Dénominateur : variance intra-groupes sur l'axe u
- Maximiser $J \Leftrightarrow$ groupes *distants* en moyenne et *compacts* individuellement

Fisher (1936)

« Trouver la direction qui sépare au mieux les groupes en écrasant la variabilité intra. »
Cette idée fonde toute la discriminance linéaire et préfigure les SVM.

7.4 — Maximisation : valeurs propres généralisées

Maximiser $J(\mathrm{u}) = (\mathrm{u}^\top \mathrm{B}\mathrm{u})/(\mathrm{u}^\top \mathrm{W}\mathrm{u})$ sous W inversible.

Lagrangien (avec normalisation $\mathrm{u}^\top \mathrm{W}\mathrm{u} = 1$) :

$$\mathcal{L}(\mathrm{u}, \mu) = \mathrm{u}^\top \mathrm{B}\mathrm{u} - \mu(\mathrm{u}^\top \mathrm{W}\mathrm{u} - 1).$$

Condition du premier ordre

$$\nabla_{\mathrm{u}} \mathcal{L} = 2\mathrm{B}\mathrm{u} - 2\mu \mathrm{W}\mathrm{u} = 0 \iff \boxed{\mathrm{B}\mathrm{u} = \mu \mathrm{W}\mathrm{u}.}$$

Theorem (Solution)

Les axes discriminants u_k *sont les vecteurs propres généralisés du couple* (B, W)*, ou de manière équivalente les vecteurs propres de* $\mathrm{W}^{-1}\mathrm{B}$*. La valeur de* J *atteint à l'optimum est* $\mu = \lambda_k$*.*

Remarque (Nombre d'axes)

On a $\mathrm{rang}(\mathrm{B}) \leq K - 1$: il existe au maximum $K - 1$ axes discriminants non triviaux.

7.5 — Cas particulier : $K = 2$ groupes

Theorem (Direction de Fisher pour 2 groupes)

Lorsque $K = 2$, l'unique axe discriminant est, à un scalaire près :

$$\mathrm{u}^* = \mathrm{W}^{-1}(\mathrm{g}_1 - \mathrm{g}_2).$$

Démonstration (idée). $\mathrm{B} = \frac{n_1 n_2}{n^2}(\mathrm{g}_1 - \mathrm{g}_2)(\mathrm{g}_1 - \mathrm{g}_2)^\top$ est de rang 1. Tout u vecteur propre de $\mathrm{W}^{-1}\mathrm{B}$ associé à la valeur propre non nulle vérifie $\mathrm{W}^{-1}(\mathrm{g}_1 - \mathrm{g}_2) \cdot c = \lambda \mathrm{u}$ pour un c, donc $\mathrm{u} \propto \mathrm{W}^{-1}(\mathrm{g}_1 - \mathrm{g}_2)$.

Lecture

Le vecteur $(\mathrm{g}_1 - \mathrm{g}_2)$ est la direction reliant les centres de gravité, modifiée par W^{-1} qui décorrèle et standardise selon la dispersion intra-classes.

Remarque

C'est exactement la *linear discriminant function* introduite par Fisher en 1936 sur les iris d'Edgar Anderson.

7.6 — Représentation des individus et des groupes

Coordonnées factorielles discriminantes

$$F_k(i) = \mathrm{x}_i^\top \mathrm{u}_k, \qquad F_k(\mathrm{g}_l) = \mathrm{g}_l^\top \mathrm{u}_k.$$

Plan factoriel discriminant

- Les individus sont colorés par leur groupe d'origine
- Les centres de gravité g_k sont projetés
- Distances dans le plan $\propto$ *distinguabilité* statistique
- Plus les centres sont éloignés, mieux les groupes sont séparables

Pouvoir discriminant des axes

$$\tau_k = \frac{\lambda_k}{\sum_{l=1}^{K-1} \lambda_l}$$

représente la part de *séparabilité* expliquée par l'axe k.

Interprétation

Si $\tau_1 > 90\%$, un *seul* axe suffit à distinguer les groupes.

7.7 — Règle de classement (versant décisionnel)

Definition (Règle de Mahalanobis)

On affecte un nouvel individu x^* à la classe minimisant la **distance de Mahalanobis** aux centres :

$$\hat{k}(x^*) = \arg\min_k (x^* - g_k)^\top W^{-1}(x^* - g_k).$$

Theorem (Forme linéaire)

*La frontière entre deux classes k et l est l'**hyperplan affine***

$$\{x : 2(g_k - g_l)^\top W^{-1} x = g_k^\top W^{-1} g_k - g_l^\top W^{-1} g_l\}.$$

La règle de classement est donc linéaire (LDA = Linear Discriminant Analysis).

Remarque

Géométriquement, on projette x^* sur les axes discriminants puis on classe par la classe la plus proche : la procédure est équivalente.

7.8 — Lien probabiliste : règle de Bayes

Hypothèse : $(X|Y=k) \sim \mathcal{N}_p(\mu_k, \Sigma_k)$, $\mathbb{P}(Y=k) = \pi_k$.

Règle de Bayes optimale (minimisant la probabilité d'erreur) :

$$\hat{k}_B(\mathrm{x}) = \arg\max_k \ \pi_k \, \phi_k(\mathrm{x}), \quad \phi_k(\mathrm{x}) = \frac{\exp\left(-\frac{1}{2}(\mathrm{x}-\mu_k)^\top \Sigma_k^{-1}(\mathrm{x}-\mu_k)\right)}{(2\pi)^{p/2}|\Sigma_k|^{1/2}}.$$

Theorem (Cas $\Sigma_k = \Sigma$ (homoscédasticité))

Si toutes les matrices de covariance sont égales, la règle de Bayes ***coïncide*** *avec l'AFD à la pondération près des π_k :*

$$\hat{k}_B(\mathrm{x}) = \arg\min_k \ (\mathrm{x}-\mu_k)^\top \Sigma^{-1}(\mathrm{x}-\mu_k) - 2\ln \pi_k.$$

Remarque (Lien Fisher / Bayes)

L'AFD est donc optimale (au sens de Bayes) sous deux hypothèses :

1. lois *conditionnelles* gaussiennes

7.9 — Analyse discriminante quadratique (ADQ / QDA)

Quand abandonner l'homoscédasticité ?

Si les groupes ont des covariances très différentes, on garde la règle de Bayes mais avec Σ_k propres à chaque classe.

Theorem (Frontière quadratique)

La règle de Bayes avec Σ_k libres donne :

$$\hat{k}(\mathrm{x}) = \arg\max_k \left[-\tfrac{1}{2} \ln |\Sigma_k| - \tfrac{1}{2}(\mathrm{x} - \mu_k)^\top \Sigma_k^{-1} (\mathrm{x} - \mu_k) + \ln \pi_k \right].$$

La frontière entre deux classes est une quadrique (généralisation de l'hyperplan).

Compromis biais / variance

- LDA : moins de paramètres, robuste à n petit
- QDA : plus flexible, exige n grand par classe
- Test d'égalité $H_0 : \Sigma_1 = \cdots = \Sigma_K$ (test de Box)

En pratique

Si $Kp(p+1)/2$ paramètres dépassent n, préférer LDA ou des variantes régularisées (RDA de Friedman).

7.10 — Évaluation : matrice de confusion et validation croisée

Definition (Matrice de confusion et taux d'erreur)

$$M_{kl} = |\{i : Y_i = k,\ \hat{Y}_i = l\}|, \qquad \text{erreur} = \frac{1}{n}\sum_{k \neq l} M_{kl}.$$

Taux d'erreur en *re-substitution*

Optimiste : on classe les individus qui ont servi à construire les axes.

Validation croisée

- Hold-out : 70% apprentissage / 30% test
- k-fold : moyenne sur k partitions
- Leave-one-out : version exacte mais coûteuse

Remarque

On reporte aussi : précision, rappel et F1 par classe ; parfois la **courbe ROC** (cas $K = 2$) ou son extension multi-classes (*one-vs-rest*).

7.11 — AFD avec R

```r
library(MASS); library(FactoMineR); library(caret)

data(iris)

# AFD (LDA) descriptive et decisionnelle
res.lda <- lda(Species ~ ., data = iris)
res.lda$svd^2 / sum(res.lda$svd^2)   # part discriminante par axe

# Plan factoriel discriminant
proj <- predict(res.lda)$x
plot(proj[, 1:2], col = iris$Species, pch = 19,
     xlab = "LD1", ylab = "LD2")
legend("topright", legend = levels(iris$Species),
       col = 1:3, pch = 19)

# Validation croisee leave-one-out
res.cv <- lda(Species ~ ., data = iris, CV = TRUE)
table(iris$Species, res.cv$class)        # matrice de confusion
mean(res.cv$class != iris$Species)        # taux d'erreur

# Analyse discriminante quadratique (QDA)
res.qda <- qda(Species ~ ., data = iris)
qda.pred <- predict(res.qda)$class
table(iris$Species, qda.pred)
```

7.12 — Récapitulatif du chapitre

À retenir

- Décomposition $V = B + W$ (Huygens)
- Critère de Fisher $J(u) = u^\top Bu / u^\top Wu$
- Solution : vecteurs propres généralisés (B, W)
- Au plus $K - 1$ axes discriminants
- Règle de Mahalanobis $\Leftrightarrow$ classement linéaire
- Optimalité bayésienne sous gaussianité + homoscédasticité
- ADQ : frontières quadratiques
- Évaluation : matrice de confusion + validation croisée

Articulation avec le cours

- **Ch. 1** : Huygens fonde le critère
- **Ch. 2** : valeurs propres généralisées
- **Ch. 6** : AFD = version supervisée de la classification

Pont vers le ML

L'AFD est une porte d'entrée vers la classification supervisée (LDA, QDA, naive Bayes gaussien, mélange de gaussiennes pour la génération).

Méthodes Avancées et Applications

8.1 — Au-delà des méthodes de base

Méthodes complémentaires

- MDS — partir de *distances* et reconstituer un nuage
- Analyse canonique — relier deux *groupes* de variables
- AFM / AFMD — analyser plusieurs *tableaux* simultanément
- PLS — régression sur variables très corrélées
- Variantes non linéaires — Kernel PCA, Isomap, t-SNE

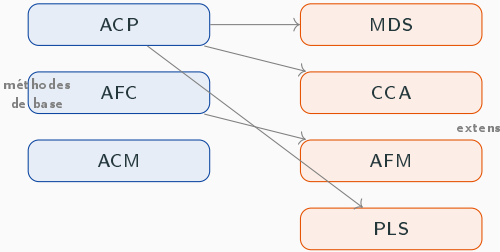

Cadre : toutes ces méthodes étendent la machinerie spectrale (Ch. 2) à des situations multi-tableaux ou non linéaires.

8.2 — Multidimensional Scaling (MDS) classique

Definition (Problème du MDS)

Étant donnée une matrice de **distances** (ou dissimilarités) $\mathrm{D} = (d_{ij}) \in \mathbb{R}^{n \times n}$ entre n objets, trouver des coordonnées $\mathrm{Y} \in \mathbb{R}^{n \times q}$ telles que :

$$\|\mathrm{y}_i - \mathrm{y}_j\| \approx d_{ij}, \quad \forall i, j.$$

Theorem (MDS classique de Torgerson)

Soit $\mathrm{B} = -\frac{1}{2}\mathrm{H}\mathrm{D}^{(2)}\mathrm{H}$ *où* $\mathrm{D}^{(2)} = (d_{ij}^2)$ *et* $\mathrm{H} = \mathrm{I}_n - \frac{1}{n}1_n 1_n^\top$ *est la matrice de centrage. Si* B *est positive, ses* q *premiers vecteurs propres fournissent* $\mathrm{Y} = \mathrm{U}_q \tilde{}_q^{1/2}$ *qui restitue exactement les* $\|\mathrm{y}_i - \mathrm{y}_j\| = d_{ij}$.

Remarque (Lien MDS / ACP)

Si d_{ij} est la distance euclidienne entre lignes d'un tableau X, le MDS classique coïncide avec l'ACP non normée (à une rotation près).

8.3 — MDS non métrique (Shepard-Kruskal)

Idée : ne préserver que l'ordre des dissimilarités, pas leurs valeurs numériques.

Definition (Stress de Kruskal)

On minimise

$$\text{Stress}(Y) = \sqrt{\frac{\sum_{i<j}(\hat{d}_{ij} - \|y_i - y_j\|)^2}{\sum_{i<j}\|y_i - y_j\|^2}}$$

où $\hat{d}_{ij}$ sont des *disparities* respectant l'ordre des d_{ij} (régression isotone).

Cas d'usage

- Dissimilarités issues d'un *questionnaire* (rangs)
- Données *phylogénétiques*, *psychométriques*
- Toute situation où la métrique est ordinale

Remarque (Critère de qualité)

Stress < 0.05 : excellent ; < 0.10 : bon ; > 0.20 : médiocre.

8.4 — Analyse Canonique des Corrélations (CCA)

Cadre : deux groupes de variables sur les mêmes individus, $\mathrm{X} \in \mathbb{R}^{n \times p}$ et $\mathrm{Y} \in \mathbb{R}^{n \times q}$.

Definition (Variables canoniques)

On cherche des combinaisons linéaires

$$U = \mathrm{X}\mathrm{a}, \qquad V = \mathrm{Y}\mathrm{b}$$

maximisant la corrélation :

$$\rho_1 = \max_{\mathrm{a},\mathrm{b}} \ \mathrm{Cor}(U, V).$$

Theorem (Solution)

Les vecteurs a, b *sont solutions du système couplé*

$$\mathrm{V}_{XX}^{-1}\mathrm{V}_{XY}\mathrm{V}_{YY}^{-1}\mathrm{V}_{YX}\,\mathrm{a} = \rho^2\mathrm{a}, \quad \mathrm{V}_{YY}^{-1}\mathrm{V}_{YX}\mathrm{V}_{XX}^{-1}\mathrm{V}_{XY}\,\mathrm{b} = \rho^2\mathrm{b}.$$

On obtient $\min(p, q)$ *couples canoniques* $(\mathrm{a}_k, \mathrm{b}_k)$ *deux à deux orthogonaux.*

Remarque

8.5 — Analyse Factorielle Multiple (AFM)

Cadre : un même ensemble d'individus décrit par plusieurs groupes de variables, possiblement hétérogènes (quantitatives + qualitatives).

Definition (Pondération AFM)

Soit $X = [X^{(1)}|X^{(2)}|\cdots|X^{(J)}]$ la concaténation de J blocs. L'AFM applique une ACP pondérée au tableau global, avec un poids $1/\lambda_1^{(j)}$ par bloc, où $\lambda_1^{(j)}$ est la première valeur propre de l'ACP du bloc j.

Theorem (Équilibrage)

Avec cette pondération, l'inertie maximale d'un axe contribuée par chaque bloc est normalisée à 1. Aucun bloc ne domine la première composante en raison de sa taille ou de son échelle.

Sorties spécifiques

- **Coordonnées** des individus, des variables, et des *groupes*
- **RV-coefficient** : mesure d'accord entre 2 groupes
- **Lg-coefficient** : généralisation au cas multi-groupes

8.6 — Régression PLS (Partial Least Squares)

Problème : régresser Y sur X avec $p \gg n$ ou X très corrélé. La régression OLS échoue ($X^\top X$ singulière).

Definition (Composantes PLS)

PLS construit successivement des composantes $t_k = Xw_k$ maximisant la covariance (et non la corrélation) avec Y :

$$w_k = \underset{\|w\|=1}{\arg\max}\ \mathrm{Cov}^2(Xw, Y),$$

puis on régresse Y sur $t_1, \ldots, t_q$.

Différence avec ACP + régression

- ACP : maximise $\mathrm{Var}(Xw)$ — ignore Y
- PLS : maximise $\mathrm{Cov}(Xw, Y)$ — combine variance et corrélation
- Avantage en **prédiction**

Remarque

La PLS est centrale en *chimiométrie* (spectres infrarouge → concentration), *génomique* (microarrays)

8.7 — Variantes non linéaires

Kernel PCA (Schölkopf, 1998)

- ACP dans un espace de Hilbert via un noyau $K(x, y)$
- Capte des structures *courbes*
- Diagonalise la matrice $\mathrm{K} = (K(x_i, x_j))$

Isomap

- MDS classique sur la distance *géodésique*
- Préserve la *topologie* d'une variété

LLE (Locally Linear Embedding)

- Reconstruit chaque point comme combinaison linéaire de ses voisins
- Pas de noyau, complexité $O(n^2)$

t-SNE et UMAP

- Préservent les *voisinages* probabilistes
- Utiles pour la *visualisation 2D*
- Pas factoriels (pas de coordonnées globales)

Critère de choix

- Données linéaires $\rightarrow$ ACP / AFC
- Variétés courbes connues $\rightarrow$ Kernel PCA
- Visualisation seulement $\rightarrow$ t-SNE / UMAP
- Spectres ou prédiction $\rightarrow$ PLS

8.8 — Études de cas métier

1. **Marketing — segmentation client**
   - Variables RFM + qualitatives
   - AFDM ou ACM + HCPC
   - Profils de classes $\rightarrow$ campagnes ciblées
2. **Finance — risque de crédit**
   - Variables continues (revenus, ratios)
   - AFD : LDA pour score
   - Validation : courbe ROC, KS
3. **Sociologie — enquête**
   - Tableau de questionnaire
   - ACM + variables sociales suppl.
   - Analyse des positions sociales (Bourdieu)
4. **Sensoriel — analyse sensorielle**
   - AFM sur jurys $\times$ descripteurs
   - Cartes de produits
   - Convergence des panels
5. **Bio-informatique — micro-arrays**
   - $p \gg n$, gènes corrélés
   - PLS ou Sparse PCA
   - Identification de signatures
6. **NLP — corpus textuel**
   - Matrice termes $\times$ documents
   - AFC / LSA
   - Topics latents

8.9 — Limites et extensions modernes

Limites des méthodes factorielles classiques

- Hypothèse de linéarité (sauf Kernel PCA)
- Sensibilité aux outliers (variantes robustes)
- Sélection des axes encore largement subjective
- Mauvaise adaptation aux données très volumineuses ($n \gg 10^6$)

Extensions modernes

- **Sparse PCA** : axes parcimonieux et interprétables
- **Robust PCA** (Candès et al.) : décompose $\mathrm{X} = \mathrm{L} + \mathrm{S}$ (low-rank + sparse)
- **Functional PCA** : pour données fonctionnelles ($y(t)$)
- **Tensor decomposition** : Tucker, CP, pour tableaux 3D+
- **Auto-encodeurs** (réseaux de neurones) : ACP non linéaire profonde
- **Topological Data Analysis** (TDA) : persistance, mapper

Filiation moderne

Les méthodes factorielles restent le squelette interprétable que les approches récentes (deep learning) cherchent à intégrer ou à remplacer.

8.10 — Méthodes avancées en R

```r
# 1) MDS classique
data(eurodist)              # distances villes
mds <- cmdscale(eurodist, k = 2, eig = TRUE)
plot(mds$points, type = "n"); text(mds$points, labels = names(eurodist))

# 2) MDS non metrique
library(MASS)
mds.nm <- isoMDS(eurodist, k = 2)

# 3) Analyse canonique (CCA)
library(CCA)
res.cca <- cc(X1, X2)
res.cca$cor                 # correlations canoniques

# 4) AFM (Multiple Factor Analysis)
library(FactoMineR)
res.afm <- MFA(don, group = c(2, 5, 3), type = c("c","c","n"),
               name.group = c("ratios","prix","categorie"))
plot(res.afm, choix = "ind")
plot(res.afm, choix = "group")

# 5) Regression PLS
library(pls)
res.pls <- plsr(y ~ ., data = train, ncomp = 10, validation = "CV")
```

8.11 — Récapitulatif du chapitre

Méthodes vues

- **MDS** (classique, non métrique)
- **Analyse canonique** (CCA)
- **AFM** (multi-tableaux)
- **PLS** (régression $p \gg n$)
- **Kernel PCA**, **Isomap**, **LLE** (non linéaire)
- **Sparse / Robust PCA**, fonctionnel, tensoriel

Ligne directrice

- Toutes ces méthodes *généralisent* la SVD
- Elles répondent à des *questions différentes*
- Choisir selon : type de données, structure recherchée, objectif

Vers la pratique

La maîtrise de ces extensions repose sur : (1) compréhension du chapitre 2, (2) choix de la *métrique* et de la *pondération*, (3) validation par les TPs.

8.12 — Conclusion générale du cours

Ce que vous savez maintenant

1. Décomposer un tableau de données en termes d'inertie
2. Choisir la *bonne* méthode factorielle selon le type de données
3. Démontrer les théorèmes fondamentaux (Spectral, SVD, Eckart-Young, Huygens)
4. Lire un plan factoriel et un cercle des corrélations
5. Construire une typologie validée (HCPC + caractérisation)
6. Mettre en œuvre tout cela en **R** (FactoMineR, factoextra, MASS)

Trois principes à retenir

1. **Géométrie d'abord** : tout est inertie, projection, distance.
2. **Une seule machine** : SVD généralisée du triplet (X, M, D_p).
3. **Toujours interpréter** : les chiffres ne parlent pas seuls, les variables et le métier oui.

Vers la suite

Les TPs en R consolident la maîtrise pratique. Le polycopié fournit les démonstrations détaillées. Bonne fin de cours !

Bibliographie

Ouvrages fondamentaux (école française)

1. **Saporta, G.** (2011). *Probabilités, analyse des données et statistique* (3e éd.). Paris : Technip. *(Référence francophone de référence.)*
2. **Lebart, L., Morineau, A., & Piron, M.** (2006). *Statistique exploratoire multidimensionnelle* (4e éd.). Paris : Dunod.
3. **Escofier, B., & Pagès, J.** (2008). *Analyses factorielles simples et multiples : objectifs, méthodes et interprétation* (4e éd.). Paris : Dunod.
4. **Husson, F., Lê, S., & Pagès, J.** (2017). *Analyse de données avec R* (2e éd.). Rennes : Presses Universitaires de Rennes.
5. **Cornillon, P.-A., Guyader, A., Husson, F. et al.** (2018). *Statistique avec R* (4e éd.). Rennes : PUR.

Auteurs historiques

6. **Benzécri, J.-P.** (1973). *L'analyse des données* (2 volumes : I — Taxinomie ; II — L'analyse des correspondances). Paris : Dunod. *(Texte fondateur de l'école française.)*
7. **Cazes, P.** (1990). Méthodes de *Statistique Descriptive Multidimensionnelle*. *Cahiers du Bureau Universitaire de Recherche Opérationnelle*.
8. **Cailliez, F., & Pagès, J.-P.** (1976). *Introduction à l'analyse des données*. Paris : SMASH.
9. **Lebart, L., & Fenelon, J.-P.** (1971). *Statistique et informatique appliquées*. Paris : Dunod.
10. **Bouroche, J.-M., & Saporta, G.** (1980). *L'analyse des données* (*Que sais-je ?*). Paris : PUF.

Manuels internationaux

11. **Hastie, T., Tibshirani, R., & Friedman, J.** (2009). *The Elements of Statistical Learning* (2e éd.). New York : Springer.
12. **Mardia, K. V., Kent, J. T., & Bibby, J. M.** (1979). *Multivariate Analysis*. London : Academic Press.
13. **Jolliffe, I. T.** (2002). *Principal Component Analysis* (2e éd.). New York : Springer.
14. **Greenacre, M.** (2017). *Correspondence Analysis in Practice* (3e éd.). Boca Raton : CRC Press.
15. **Izenman, A. J.** (2008). *Modern Multivariate Statistical Techniques*. New York : Springer.

Articles séminaux — ACP et SVD

16. **Pearson, K.** (1901). On lines and planes of closest fit to systems of points in space. *Philosophical Magazine*, 2(11), 559–572. *(Origine de l'ACP.)*
17. **Hotelling, H.** (1933). Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24, 417–441 et 498–520.
18. **Eckart, C., & Young, G.** (1936). The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3), 211–218.
19. **Mirsky, L.** (1960). Symmetric gauge functions and unitarily invariant norms. *Quarterly Journal of Mathematics*, 11(1), 50–59.
20. **Jolliffe, I. T., & Cadima, J.** (2016). Principal component analysis : a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374.

Articles séminaux — AFC, ACM, classification

21. **Benzécri, J.-P.** (1969). Statistical analysis as a tool to make patterns emerge from data. *Methodologies of Pattern Recognition*, 35–74.
22. **Greenacre, M., & Blasius, J.** (Eds.) (2006). *Multiple Correspondence Analysis and Related Methods*. Boca Raton : Chapman & Hall/CRC.
23. **Ward, J. H.** (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236–244.
24. **MacQueen, J.** (1967). Some methods for classification and analysis of multivariate observations. *Berkeley Symposium on Mathematical Statistics*, 1, 281–297.
25. **Arthur, D., & Vassilvitskii, S.** (2007). k-means++ : The advantages of careful seeding. *Proc. SODA 2007*, 1027–1035.
26. **Rousseeuw, P. J.** (1987). Silhouettes : A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

Articles séminaux — AFD et méthodes avancées

27. **Fisher, R. A.** (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. *(Origine de la LDA.)*
28. **Hotelling, H.** (1936). Relations between two sets of variates. *Biometrika*, 28(3/4), 321–377. *(Analyse canonique.)*
29. **Torgerson, W. S.** (1952). Multidimensional scaling : I. Theory and method. *Psychometrika*, 17, 401–419.
30. **Kruskal, J. B.** (1964). Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. *Psychometrika*, 29(1), 1–27.
31. **Wold, H.** (1975). Soft modelling by latent variables : The non-linear iterative partial least squares (NIPALS) approach. *Perspectives in Probability and Statistics*, 117–142. *(Régression PLS.)*

Références vii

32. **Schölkopf, B., Smola, A., & Müller, K.-R.** (1998). Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5), 1299–1319.
33. **Tenenbaum, J. B., de Silva, V., & Langford, J. C.** (2000). A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500), 2319–2323. *(Isomap.)*
34. **Roweis, S. T., & Saul, L. K.** (2000). Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290(5500), 2323–2326. *(LLE.)*
35. **Candès, E. J., Li, X., Ma, Y., & Wright, J.** (2011). Robust principal component analysis ? *Journal of the ACM*, 58(3), 1–37.

Méthodes contemporaines

36. **Zou, H., Hastie, T., & Tibshirani, R.** (2006). Sparse principal component analysis. *Journal of Computational and Graphical Statistics*, 15(2), 265–286.
37. **van der Maaten, L., & Hinton, G.** (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
38. **McInnes, L., Healy, J., & Melville, J.** (2018). UMAP : Uniform manifold approximation and projection for dimension reduction. *arXiv :1802.03426*.
39. **Ramsay, J. O., & Silverman, B. W.** (2005). *Functional Data Analysis* (2e éd.). New York : Springer.
40. **Kolda, T. G., & Bader, B. W.** (2009). Tensor decompositions and applications. *SIAM Review*, 51(3), 455–500.
41. **Carlsson, G.** (2009). Topology and data. *Bulletin of the AMS*, 46(2), 255–308. *(TDA.)*

Logiciels et packages R

42. **Lê, S., Josse, J., & Husson, F.** (2008). FactoMineR : An R package for multivariate analysis. *Journal of Statistical Software*, 25(1), 1–18. `factominer.free.fr`
43. **Kassambara, A., & Mundt, F.** (2020). *factoextra : Extract and Visualize the Results of Multivariate Data Analyses*. R package version 1.0.7.
44. **Dray, S., & Dufour, A.-B.** (2007). The ade4 package : implementing the duality diagram for ecologists. *Journal of Statistical Software*, 22(4), 1–20.
45. **Venables, W. N., & Ripley, B. D.** (2002). *Modern Applied Statistics with S* (4e éd.). Springer. *(Package `MASS` : lda, qda, isoMDS.)*
46. **R Core Team** (2024). *R : A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna. `www.R-project.org`

Ressources en ligne et communauté

Sites web et MOOC

- **factominer.free.fr** — site officiel FactoMineR (Husson & Lê)
- **rdrr.io/cran/FactoMineR** — documentation interactive
- **r-graph-gallery.com** — visualisations factorielles
- **MOOC *Analyse des Données Multidimensionnelles*** (FUN, Husson & Lê, AGROCAMPUS Ouest)
- **distill.pub** — articles visuels sur t-SNE, UMAP

Références xi

Conférences clés

- **CARME** — Conferences on Correspondence Analysis and Related Methods
- **IFCS** — International Federation of Classification Societies
- **Rencontres R** (France) — communauté R francophone